INFOESTE 2026 · ALÉM DO CÓDIGO

Guia Analista e Cientista

Do dado bruto à decisão: SQL, pandas, Power BI, DAX e ciência de dados

PARA QUEM

Quem vai analisar dados e apoiar decisões

INSTRUTORES

Lucas Galindo e Lucas Araujo

VERSÃO

1.0 · outubro de 2026

Como usar este guia

Este guia acompanha os slides dos dois dias do curso. Ele foi escrito para quem vai **analisar dados e apoiar decisões**: analista de dados, analista de BI e quem quer começar em ciência de dados. A ideia é simples: ler, entender, testar no seu computador e só então chegar na aula.

Cada capítulo tem a mesma estrutura:

- **Em uma frase:** a ideia central, para memorizar.
- **Como funciona:** o conteúdo técnico, sem enrolação.
- **Na AgroMaq:** o mesmo conceito aplicado à fábrica do curso.
- **Teste você:** exercícios para fazer sozinho, com a resposta esperada para conferir.

> **Tempo total de estudo:** cerca de 8 a 10 horas, em três ou quatro sessões. Faça os testes com calma. O que você digita fica na memória; o que você só lê, não.

Mapa do guia

Capítulo	O que você aprende	Slides	Estudo
1. O cenário	AgroMaq, caminho do dado, três níveis de pergunta	Dia 1 · 2 a 7	30 min
2. As profissões	Onde analista, engenheiro e cientista se encontram	Dia 1 · 8 a 12	20 min
3. SQL para quem analisa	SELECT, JOIN, GROUP BY, HAVING	Dia 1 · 13 e 14	90 min
4. pandas para explorar	read_csv, info, describe, isna, .loc, pandas 3.0	Dia 1 · 15 e 16	60 min
5. Qualidade de dado	Seis defeitos e o pico que não se apaga	Dia 1 · 21 e 26	40 min
6. Modelo estrela	Fato, dimensão, granularidade, chaves	Dia 1 · 23, Dia 2 · 3 e 4	40 min
7. Power BI	Desktop, Power Query, modelo, medidas, três páginas	Dia 2 · 6 a 12	120 min
8. DAX essencial	Contexto de filtro e seis funções	Dia 2 · 13 e 14	90 min
9. IA em dashboards	Visuais de IA, quatro padrões, riscos	Dia 2 · 15 e 16	40 min
10. Ciência de dados	Ciclo, estatística, conceitos de modelo, cargos	Dia 2 · 17 a 21	90 min
11. Insights	Do número à ação	Dia 2 · 22	30 min
12. Carreira	Certificações e próximos passos	Dia 2 · 21 e 23	20 min

O que você precisa instalar

Ferramenta	Para quê	Observação
MySQL 8 e MySQL Workbench	Rodar o banco e escrever SQL	Use o mesmo da aula
Python 3.11 ou mais novo	Rodar o pandas	Com `pandas` 3.0 (`pip install pandas`)
Power BI Desktop	Construir o dashboard	Só Windows
Oracle MySQL Connector/NET	Power BI falar com o MySQL	Instale antes do Power BI abrir o banco

Atenção. Em máquinas de instituição, a instalação pode pedir permissão de administrador. Teste a conexão do Power BI com o MySQL **antes** do Dia 2. Se o conector não funcionar, existe plano B: importar os arquivos CSV do laboratório (Capítulo 7).

O laboratório de estudo

Para você treinar sem depender da aula, existe um laboratório pequeno: um CSV com leituras de sensores reais do banco da AgroMaq, **com defeitos plantados**, e um data warehouse já montado a partir dele. O passo a passo para instalar está no **Apêndice A**.

Importante. O laboratório não é o CSV oficial da aula e os nomes das tabelas dele podem diferir dos que usaremos em sala. Ele existe para você praticar as mesmas ideias. Os números que aparecem nos "Teste você" valem para o laboratório.

Convenções

Dica. Atalho ou boa prática que economiza tempo.

Atenção. Armadilha comum. Quase todo mundo cai uma vez.

Conceito. Definição para memorizar.

Teste você. Exercício prático. Cada um traz o **resultado esperado** para você conferir. A solução completa fica no gabarito dos instrutores.

1. O cenário: AgroMaq e o caminho do dado

Slides: Dia 1, 2 a 7 · Estudo: 30 minutos

> **Em uma frase.** Dado só vira decisão quando alguém o torna confiável.

A AgroMaq

Durante os dois dias, o cliente é a **AgroMaq**, uma fábrica de máquinas agrícolas com duas unidades:

Unidade	Cidade	O que fabrica
1	Presidente Prudente (SP)	Tratores e colhedoras
2	Três Lagoas (MS)	Plantadoras e pulverizadores

O banco operacional se chama `agromaq_industrial` e tem **38 tabelas**, **120 máquinas** e **316 sensores**. Cada sensor registra uma leitura por hora. No período completo do curso, de 01/01/2026 a 10/10/2026, isso dá cerca de **2,15 milhões de leituras** (316 sensores × 24 horas × 283 dias).

A hierarquia que você vai ver o tempo todo:

Nível	Exemplo
Unidade	Presidente Prudente
Linha de produção	Linha de Corte - Trator
Máquina	Máquina de Corte a Laser
Sensor	SEN00001 (Temperatura Motor)
Leitura	Um valor, em um horário

O caminho do dado até a decisão

BI (*Business Intelligence*) é o caminho que o dado percorre até virar uma decisão. São cinco etapas, e se uma falha, a decisão final sai errada:

Etapa	O que acontece	Exemplo na AgroMaq
1. Fontes	Onde o dado nasce	ERP, 316 sensores e planilhas de venda
2. Integração	O ETL tira o dado das fontes e o trata	Limpar leituras duplicadas
3. Armazenamento	Data warehouse com fatos e dimensões	Tabelas organizadas para análise

Etapa	O que acontece	Exemplo na AgroMaq
4. Análise	SQL e Power BI respondem às perguntas	Quantas leituras saíram da faixa?
5. Decisão	Alguém age	Parar a máquina ou ajustar a produção

Para o analista. Você trabalha nas etapas 4 e 5, mas só confia no resultado se entender as etapas 1 a 3. A pergunta que abre o curso é a que você deve fazer sempre: **quem já viu um relatório com número errado?** Em geral, o erro nasceu antes da análise.

Dado, informação e conhecimento

Uma mesma leitura muda de valor conforme o contexto que ganha:

Camada	Exemplo (valor ilustrativo)	O que falta para subir
Dado	92 °C	Contexto: de qual sensor? Quando?
Informação	92 °C no sensor de temperatura do motor, às 14h, acima do limite da máquina	Histórico para explicar
Conhecimento	Esse rolamento aquece antes de falhar	Decisão
Decisão	Agendar a manutenção antes da próxima parada	

Três níveis de resposta

A mesma máquina permite perguntas cada vez mais difíceis, e cada degrau exige mais dado, **e dado de mais qualidade**:

Nível	Pergunta	Exemplo
Descritiva	O que aconteceu?	Quanto produzimos no mês?
Preditiva	O que vai acontecer?	Qual máquina vai falhar?
Prescritiva	O que fazer?	Qual manutenção agendar primeiro?

Alguns livros incluem um nível entre os dois primeiros, o **diagnóstico** (“por que aconteceu?”). É o trabalho do analista quando cruza paradas, turno e linha para achar a causa.

Teste você 1.1. Classifique cada pergunta como descritiva, diagnóstica, preditiva ou prescritiva:

1. Quantas leituras de temperatura chegaram ontem?
2. Por que a Linha de Soldagem teve mais refugo em março?
3. Qual colhedora deve parar nos próximos dias?
4. Qual das três máquinas devemos revisar primeiro?

5. Qual é a temperatura média do sensor SEN00001?

Depois, escreva uma sexta pergunta de cada nível sobre a AgroMaq. Se você consegue inventar perguntas, entendeu a escada.

2. As profissões: onde cada um entra

Slides: Dia 1, 8 a 12 · Estudo: 20 minutos

> **Em uma frase.** Três profissões, um objetivo: decisão confiável.

Quem faz o quê

	Analista	Engenheiro	Cientista
Pergunta	O que aconteceu e por quê?	O dado chega certo e todo dia?	O que vai acontecer?
Ferramentas	SQL, Excel, Power BI	SQL, Python, pipelines	Python, estatística
Entrega	Relatório e painel	Tabelas confiáveis	Modelos e previsões

Existe também o **engenheiro de analytics**, que fica entre o engenheiro e o analista: modela e testa o dado para a análise (ferramenta típica: SQL e dbt). As fronteiras entre os cargos mudam de empresa para empresa. Um anúncio de "analista" pode pedir Python; um de "cientista" pode pedir só dashboard.

A rotina do analista

1. Recebe uma pergunta do negócio.
2. Consulta e organiza os dados.
3. Monta o gráfico e explica o resultado.

Exemplo na AgroMaq: *qual linha de produção gera mais refugo?*

A rotina do cientista

1. Explora os dados atrás de padrões.
2. Treina modelos para prever.
3. Mede se o modelo é confiável.

O cientista só aparece com mais detalhe no Dia 2 (Capítulo 10). Hoje ele é uma pincelada.

Os três em sequência

Imagine que uma colhedora para no meio do turno:

Quem	O que faz	Resultado
Engenheiro	Garante leituras completas e sem duplicata	Dado confiável
Analista	Cruza paradas, turno e linha para achar o motivo	A **causa**

Quem	O que faz	Resultado
Cientista	Usa o histórico para avisar antes da próxima parada	A **previsão**

Atenção. Sem o primeiro passo bem feito, os outros dois trabalham em cima de dado errado. Por isso o Dia 1 inteiro é sobre confiança no dado, mesmo para quem vai ser analista.

Teste você 2.1. Pesquise três vagas reais (de analista de dados, de BI e de cientista) e anote: quais ferramentas aparecem em todas? Qual aparece só em uma? Isso mostra, na prática, onde as fronteiras se misturam.

3. SQL para quem analisa

Slides: Dia 1, 13 e 14 · Estudo: 90 minutos

> **Em uma frase.** SQL é a língua comum de todas as profissões de dados: é com ela que você pergunta ao banco.

Onde o SQL entra

Cada camada do dado tem sua ferramenta:

Camada	Ferramenta	Papel
Guardar	MySQL	O banco da fábrica e o data warehouse
Consultar	**SQL**	A língua para perguntar ao banco
Tratar	Python	Perfilar, limpar e automatizar
Mostrar	Power BI	Dashboards para decidir

Quando o volume cresce, aparecem Airflow, dbt, Spark e a nuvem. Neste curso eles são só menção.

A consulta completa, em blocos

Todo `SELECT` que você vai escrever cabe neste molde. Os blocos opcionais ficam entre colchetes:

```
SELECT   colunas e cálculos
FROM     tabela principal
[JOIN    outra tabela ON condição]
[WHERE   filtro sobre as linhas]
[GROUP BY colunas de agrupamento]
[HAVING  filtro sobre os grupos]
[ORDER BY ordenação]
[LIMIT   quantidade];
```

O banco não executa na ordem em que você escreve. A ordem **lógica** é esta, e entendê-la evita metade dos erros:

Ordem	Bloco	Pergunta que responde
1	`FROM` e `JOIN`	De onde vêm as linhas?
2	`WHERE`	Quais linhas ficam?
3	`GROUP BY`	Como agrupar?
4	`HAVING`	Quais grupos ficam?
5	`SELECT`	Quais colunas mostrar?

Ordem	Bloco	Pergunta que responde
6	`ORDER BY` e `LIMIT`	Em que ordem e quantas?

> **Atenção.** `WHERE` filtra **linhas antes** de agrupar; `HAVING` filtra **grupos depois** de agrupar. Para filtrar por `COUNT(*)`, só `HAVING` funciona.

Os comandos básicos

Contar e conhecer a tabela

```
SELECT COUNT(*) FROM maquina;           -- 120
SELECT COUNT(*) FROM sensor;            -- 316
SELECT * FROM maquina LIMIT 5;          -- espiar 5 linhas
```

Filtrar e ordenar

```
SELECT nome
FROM tipo_sensor
WHERE nome LIKE 'Temperatura%'          -- % = qualquer texto
ORDER BY nome;
```

Agrupar e contar (o coração da análise)

```
SELECT tipo, COUNT(*) AS maquinas
FROM maquina
GROUP BY tipo
ORDER BY maquinas DESC;
```

As funções de agregação que você mais usa: `COUNT`, `SUM`, `AVG`, `MIN`, `MAX`.

> **`COUNT(*)` ou `COUNT(coluna)`?** `COUNT(*)` conta linhas. `COUNT(coluna)` conta só as linhas em que a coluna **não é nula**. A diferença entre os dois é uma forma rápida de descobrir nulos.

JOIN: ligar tabelas

Dados bem organizados ficam em várias tabelas. O `JOIN` liga uma à outra pela chave:

```
SELECT t.nome AS tipo_sensor,
       COUNT(*) AS sensores
FROM sensor s
JOIN tipo_sensor t
  ON t.id_tipo_sensor = s.tipo_sensor_id
GROUP BY t.nome
ORDER BY sensores DESC
LIMIT 5;
```

Esta é a consulta do slide 14. Leia assim: *"para cada sensor, traga o nome do seu tipo; agrupe por tipo; conte; mostre os cinco maiores."*

Parte	O que faz
`JOIN ... ON`	Liga cada sensor ao seu tipo
`GROUP BY`	Agrupa os sensores por tipo
`COUNT(*)`	Conta os sensores de cada grupo
Apelidos (*aliases*)	`s` para sensor e `t` para tipo, para escrever menos

Resultado esperado (os dois últimos empatam em 24, e a ordem entre empatados pode variar):

tipo_sensor	sensores
Status Operacional	56
Posicao Linear	44
Temperatura Motor	36
Velocidade de Corte / Vibracao Geral	24

`INNER JOIN` × `LEFT JOIN`. O `JOIN` simples (*inner*) só traz linhas que têm par nas duas tabelas. O `LEFT JOIN` traz **todas** as da esquerda, com `NULL` onde não há par. É a ferramenta para achar o que falta:

```
SELECT t.nome
FROM tipo_sensor t
LEFT JOIN sensor s ON s.tipo_sensor_id = t.id_tipo_sensor
WHERE s.id_sensor IS NULL;      -- tipos cadastrados sem nenhum sensor
```

> **Atenção ao `NULL`.** `valor = NULL` nunca é verdadeiro. Use `valor IS NULL` ou `valor IS NOT NULL`.

Como ler o schema da AgroMaq

Você não precisa decorar as 38 tabelas. Para este guia, basta seguir a cadeia:

Tabela	Chave	Liga com
`unidade`	`id_unidade`	`categoria_produto.unidade_id`
`categoria_produto`	`id_categoria`	`linha_producao.categoria_id`
`linha_producao`	`id_linha`	`maquina.linha_id`
`maquina`	`id_maquina`	`sensor.maquina_id`
`tipo_sensor`	`id_tipo_sensor`	`sensor.tipo_sensor_id`
`sensor`	`id_sensor`	`leitura_sensor.sensor_id`

Estratégia. Diante de uma tabela nova, faça sempre três coisas: `SELECT COUNT(*)`, `SELECT * ... LIMIT 5` e `SHOW CREATE TABLE nome;` para ver chaves e tipos.

Teste você

Teste você 3.1. Conte as linhas de `maquina` e de `sensor`.

Resultado esperado: 120 máquinas e 316 sensores.

Teste você 3.2. Quantos sensores são do tipo `Temperatura Motor`? (Precisa de `JOIN` com `tipo_sensor`.)

Resultado esperado: 36.

Teste você 3.3. Quais são os três tipos de máquina (`maquina.tipo`) mais frequentes? Em caso de empate, ordene pelo nome do tipo.

Resultado esperado: Torquimetro Pneumatico (12), Esteira Transportadora (8), Ponte Rolante 10t (8).

Teste você 3.4. Quantas máquinas têm exatamente 3 sensores? (Dica: agrupe `sensor` por `maquina_id`, use `HAVING` e depois conte os grupos.)

Resultado esperado: 76.

Teste você 3.5. Quantos sensores de `Temperatura Motor` existem em cada categoria de produto (Trator, Colhedora, Plantadora, Pulverizador)? Você vai precisar de `JOIN` em cinco tabelas.

Resultado esperado: 9 em cada uma das quatro categorias (36 no total).

Teste você 3.6. Quantos tipos de sensor estão cadastrados em `tipo_sensor`, mas não têm nenhum sensor instalado? (`LEFT JOIN` e `IS NULL`.)

Resultado esperado: 25. Dos 40 tipos cadastrados, só 15 estão em uso.

Teste você 3.7 (desafio). Existe alguma máquina sem sensor? E alguma linha de produção sem máquina?

Resultado esperado: nenhuma das duas.

Antes de seguir. Você consegue explicar, sem olhar, a diferença entre `WHERE` e `HAVING`, e entre `JOIN` e `LEFT JOIN`? Se sim, o capítulo está dominado.

4. pandas para explorar dados

Slides: Dia 1, 15 e 16 · Estudo: 60 minutos

> **Em uma frase.** O pandas coloca uma tabela na memória do Python e deixa você inspecioná-la, filtrá-la e corrigi-la em poucas linhas.

Cada biblioteca resolve um pedaço

Biblioteca	Para quê	Onde aparece no curso
pandas	Tabelas em memória	Prática P4: perfilar o CSV
NumPy	Cálculo numérico	Base do pandas
SQLAlchemy (com PyMySQL)	Ponte com o MySQL	Ler o banco no Python
Matplotlib	Gráficos rápidos	Conferir o dado
Faker	Dados fictícios	Só os instrutores usam

Para analisar, o pandas basta. As outras são apoio.

O pandas 3.0 mudou duas regras

Muito material antigo na internet foi escrito para versões anteriores. Duas mudanças pegam iniciantes:

Regra 1: coluna de texto vira `str`. Antes o tipo era `object`; agora o texto tem tipo próprio.

```
df["cidade"].dtype      # str  (antes: object)
```

Regra 2: atribuição encadeada deixa de funcionar. Para alterar valores, use `.loc` em um único passo.

```
# ERRADO: não altera df, e o pandas avisa (ChainedAssignmentError)
df[df["valor"] < 0]["valor"] = None

# CERTO: uma operação só, com .loc
df.loc[df["valor"] < 0, "valor"] = None
```

> **Atenção.** Em pandas 3.0, `df[condição]["coluna"] = valor` **não muda nada** no original. Você vê o aviso, mas o dado continua sujo. Sempre use `.loc[linhas, coluna] = valor`.

Confira sua versão com `import pandas as pd; pd.__version__` (deve começar com 3).

Receita de exploração

Esta sequência serve para qualquer tabela nova. Use o CSV do laboratório (`leituras_lab.csv`):

```
import pandas as pd

# dtype=str: lê tudo como texto, sem o pandas "adivinhar" tipos
df = pd.read_csv("leituras_lab.csv", dtype=str)

df.shape                # (linhas, colunas)
df.head()               # primeiras 5 linhas
df.info()               # colunas, tipos, não-nulos
df.describe()           # resumo (em texto: contagem, únicos, mais frequente)
df.isna().sum()         # nulos por coluna
df.duplicated().sum()   # linhas totalmente repetidas
```

> **Por que `dtype=str`?** Quando o dado chega sujo, deixar o pandas inferir tipos esconde problemas (uma vírgula decimal transforma a coluna inteira em texto, uma data diferente vira texto). Ler tudo como texto, **olhar** e só depois converter é o caminho seguro. É o mesmo princípio da staging em VARCHAR do banco.

Funções que você vai repetir

Quero	Código
Contar valores de uma coluna	`df["tipo_maquina"].value_counts()`
Limpar texto	`df["tipo_maquina"].str.strip().str.lower()`
Trocar vírgula por ponto	`df["valor"].str.replace(",", ".")`
Converter para número	`pd.to_numeric(serie)`
Converter para data	`pd.to_datetime(serie, format="%Y-%m-%d %H:%M:%S", errors="coerce")`
Linhas repetidas por chave	`df.duplicated(subset=["sensor_id", "data_hora"])`
Substituir com condição	`df.loc[df["valor"] == -999, "valor"] = None`
Resumo por grupo	`df.groupby("sensor_id")["valor"].agg(["count", "mean", "std"])`

`errors="coerce"` transforma o que não consegue converter em vazio (`NaT` ou `NaN`) em vez de quebrar. Muito útil para **achar** o que está fora do padrão.

Teste você

> **Teste você 4.1.** Leia o CSV como texto. Qual é o formato (`shape`)? Todas as colunas têm tipo `str`?
>
> *Resultado esperado:* 8.626 linhas e 5 colunas, todas `str`.

Teste você 4.2. Conte os nulos de cada coluna.

Resultado esperado: só `valor` tem nulos: 60.

Teste você 4.3. Conte as linhas repetidas considerando `sensor_id`, `data_hora` e `valor`.

Resultado esperado: 80.

Teste você 4.4. Quantas linhas têm `valor` igual a `"-999"`? Quantas têm vírgula decimal (por exemplo `"71,5"`)?

Resultado esperado: 45 com `-999` e 50 com vírgula.

Teste você 4.5. Use `value_counts()` em `tipo_maquina`. Quantas variantes aparecem? Depois aplique `.str.strip().str.lower()` e conte de novo.

Resultado esperado: 16 variantes (por exemplo `Trator`, `trator`, `TRATOR`, `Trator` com espaço no fim); 4 depois da limpeza.

Teste você 4.6. Quantas datas fogem do padrão `AAAA-MM-DD HH:MM:SS`? (Use `str.match` com a expressão `r"^\d{4}-\d{2}-\d{2} \d{2}:\d{2}:\d{2}$"`.)

Resultado esperado: 90.

Teste você 4.7 (pandas 3.0). Crie um `DataFrame` pequeno com uma coluna `valor` com um número negativo. Tente zerar o negativo da forma errada e da forma certa. O que acontece em cada uma?

Resultado esperado: a forma encadeada emite `ChainedAssignmentError` e **não** altera o dado; a forma com `.loc` altera.

SQL ou pandas?

Os dois fazem perfilamento, e no curso você fará nos dois para **comparar os números**. Uma regra prática:

Situação	Melhor ferramenta
Dado já está no banco, volume grande	SQL
Arquivo solto (CSV, planilha), exploração rápida	pandas
Gráfico e estatística	pandas
Resultado precisa ser repetível todo dia	Qualquer um, mas em script

Antes de seguir. Os números do pandas devem bater com os do SQL. Quando não batem, um dos dois está lendo o dado de um jeito diferente, e descobrir qual é o melhor exercício de análise que existe.

5. Qualidade de dado sob o olhar de quem analisa

Slides: Dia 1, 21 e 26 · Estudo: 40 minutos

> **Em uma frase.** Dado real chega sujo, e todo defeito não tratado vira número errado no seu dashboard.

Seis defeitos clássicos

Defeito	Exemplo	Efeito na sua análise
Nulo	Temperatura vazia	Médias e contagens ficam diferentes conforme a ferramenta trata o vazio
Duplicado	A mesma leitura, duas vezes	Totais e contagens inflados
Sentinela	Um código (como `-999`) no lugar do valor	Médias absurdas, desvios gigantes
Órfão	Leitura de um sensor que não existe	Fato sem dimensão: some dos filtros ou vira "em branco"
Formato	Datas e números escritos de formas diferentes	Valor lido como texto, datas trocadas (dia e mês invertidos)
Texto solto	Trator, trator, TRATOR	O mesmo grupo aparece como três barras no gráfico

Os exemplos são ilustrativos, mas o laboratório tem todos eles, em quantidades conhecidas.

O efeito de um único defeito

Veja o que o valor sentinela faz com a média. No laboratório, o sensor `16` tem 5 leituras com `-999`:

Cálculo (sensor 16)	Média	Desvio padrão
Com as leituras `-999`	68,34	63,45
Sem elas	72,09	3,87

Cinco linhas em mais de mil derrubaram a média em quase 4 graus e multiplicaram o desvio por 16. Quem olhasse só a média nem perceberia a causa.

O pico que não se apaga

> **Nem todo pico é erro.** Apagar um pico legítimo também é perder dado. Regra de negócio vale mais que regra de bolso: conheça o dado antes de apagar.

No laboratório, o sensor `16` (temperatura do motor de uma Furadeira CNC) sobe de 98,4 °C para 121,3 °C entre 12h e 16h do dia 12/03/2026, e volta ao normal. Para quem não conhece a máquina, parece erro de leitura. Para a manutenção, pode ser o aviso de uma falha que **aconteceu**.

Uma regra comum de bolso é "descartar o que passa de 3 desvios padrão". Veja o que ela faz **na ordem errada**:

Ordem	O que a regra marca (sensor 16)
Aplicar a regra com o `-999` ainda no dado	As 5 leituras `-999` (e **não** o pico)
Remover o `-999` primeiro e depois aplicar	As 5 leituras do pico: 98,4 / 105,2 / 112,7 / 118,9 / 121,3

Duas lições:

1. **A ordem do tratamento importa.** Primeiro o defeito claro (sentinela), depois a análise estatística.
2. **A estatística aponta o suspeito; quem decide é o negócio.** A regra dos 3 desvios encontra o pico, mas só a equipe de manutenção diz se ele é falha de sensor ou aviso real.

Duplicata: às vezes só aparece depois de padronizar

Olhando o texto como veio, o laboratório mostra **80** linhas repetidas. Depois de padronizar as datas (algumas vêm como `15/03/2026 14:00`), aparecem **100**. As 20 a mais estavam escondidas pelo formato.

> **Regra de ouro.** Padronize formatos **antes** de procurar duplicatas, e confira a contagem antes e depois de cada etapa.

Dado ruim derruba a IA também

O mesmo defeito que atrapalha o relatório vira resposta errada em um assistente ou modelo: o sensor com `-999` entra como se fosse medida, e a média sai torta, dita com confiança. Qualidade de dado é pré-requisito de IA. O pipeline do Dia 1 protege a IA de amanhã.

Teste você

> **Teste você 5.1.** No pandas, converta `valor` para número (trocando vírgula por ponto) e calcule a média e o desvio padrão do sensor `16` **com** e **sem** as leituras `-999`.
>
> *Resultado esperado:* média 68,34 e desvio 63,45 com; média 72,09 e desvio 3,87 sem.

Teste você 5.2. Para o sensor `16`, calcule o z-score (`(valor - média) / desvio`) e conte quantas leituras têm `|z| > 3`, primeiro com o `-999` e depois sem. Quais valores aparecem em cada caso?

Resultado esperado: 5 nos dois casos, mas com `-999` são as cinco leituras sentinela e sem ele são 98,4, 105,2, 112,7, 118,9 e 121,3.

Teste você 5.3. Converta `data_hora` para data usando os dois formatos (`"%Y-%m-%d %H:%M:%S"` e `"%d/%m/%Y %H:%M"`) e conte as linhas duplicadas pela chave (`sensor_id`, data) em vez do texto.

Resultado esperado: 100 duplicadas pela chave, contra 80 pelo texto.

Teste você 5.4 (reflexão). O pico do sensor 16 sumiria de um dashboard se alguém aplicasse "remova tudo acima de 100 °C"? E se o analista não soubesse da regra? Escreva em duas linhas o que você perguntaria à equipe de manutenção antes de decidir.

6. Modelo estrela para quem consome o dado

Slides: Dia 1, 19 e 23 · Dia 2, 3, 4 e 8 · Estudo: 40 minutos

> **Em uma frase.** Fato é o que se mede; dimensão é o contexto para fatiar. O cupom fiscal é o fato; o cadastro de produto e de cliente são dimensões.

Um banco opera, outro analisa

	OLTP (opera)	OLAP (analisa)
Exemplo	`agromaq_industrial`, com 38 tabelas	O data warehouse, com poucas tabelas em estrela
Escrita e leitura	Grava uma leitura por vez	Lê milhões de linhas de uma vez
Feito para	Registrar rápido	Responder rápido

Um não substitui o outro: o **ETL** leva o dado de um para o outro. Para você, analista, a consequência é boa: o DW já vem no formato que o Power BI quer.

Fato e dimensão

	Fato	Dimensão
O que guarda	O que aconteceu, com números	Quando, onde, quem
Exemplos	Uma leitura de sensor; uma ordem de produção	tempo, sensor, máquina, linha, produto
Tamanho	Milhões de linhas	Dezenas ou milhares
Colunas típicas	Chaves das dimensões + medidas (valor, quantidade)	Atributos descritivos (nome, tipo, unidade)

A **primeira decisão** de um modelo é a **granularidade**: *uma linha da fato representa o quê?* Na AgroMaq, `fato_leitura_sensor` tem **uma linha por sensor por hora**; `fato_producao` terá uma linha por ordem ou lote (a granularidade exata é confirmada no DDL do DW).

> **Atenção.** Misturar granularidades na mesma fato (por exemplo, uma linha por hora junto com uma linha por dia) faz as somas darem errado. Defina a granularidade primeiro e escreva-a em uma frase.

A dimensão achata a hierarquia

No banco operacional, um sensor fica no fim de uma cadeia: sensor, máquina, linha, unidade. Para analisar, ninguém quer fazer quatro `JOIN`s a cada pergunta. No DW, a dimensão `dim_sensor` é **uma linha larga**, com máquina, linha e unidade juntas:

sk_sensor	codigo_sensor	tipo_sensor	nome_maquina	nome_linha	categoria	unidade
1	SEN00001	Temperatura Motor	Maquina de Corte a Laser	Linha de Corte - Trator	Trator	Unidade Presidente Prudente

Filtrar por unidade, por linha ou por categoria passa a ser um clique no Power BI.

Chave natural e chave substituta

	Chave natural	Chave substituta
O que é	O código que vem do sistema de origem	Um número criado pelo próprio DW
Exemplo	`id_sensor_origem` = 16	`sk_sensor` = 16
Para que serve	Reconhecer o mesmo sensor em cargas futuras	Ligar fato e dimensão de forma estável e rápida

A estrela do laboratório

O laboratório tem uma versão pequena do DW da AgroMaq:

Tabela	Tipo	Granularidade	Linhas
`dim_tempo`	Dimensão	1 linha por **dia**	59
`dim_sensor`	Dimensão (larga)	1 linha por sensor	316
`dim_maquina`	Dimensão	1 linha por máquina	120
`dim_linha`	Dimensão	1 linha por linha de produção	40
`fato_leitura_sensor`	Fato	1 linha por sensor por hora	8.391

> **Por que a `dim_tempo` é diária?** A tabela de datas do Power BI exige **uma data por linha**, sem repetição. Se a dimensão fosse por hora, o mesmo dia apareceria 24 vezes e as funções de tempo do DAX (como "mês anterior") não funcionariam. Por isso a hora e o turno ficam na própria fato. É uma decisão de modelagem que você vai reencontrar.

`dim_maquina` e `dim_linha` existem para a futura `fato_producao`; para as leituras, a `dim_sensor` já traz esses atributos.

Como o Power BI enxerga isso

No modelo do Power BI, cada dimensão se liga à fato por uma relação **um para muitos** (*uma máquina, muitas leituras*), e o filtro **desce da dimensão para a fato**: ao escolher "Março" na dimensão de tempo, a fato mostra só as leituras de março.

Teste você

Estes testes usam o DW pronto. Importe `lab_dw_pronto.sql` (Apêndice A) e use o banco `agromaq_lab`.

> **Teste você 6.1.** Conte as linhas de cada tabela do DW.
>
> *Resultado esperado:* `dim_linha` 40, `dim_maquina` 120, `dim_sensor` 316, `dim_tempo` 59, `fato_leitura_sensor` 8.391.
>
> **Teste você 6.2.** Quantas leituras fora da faixa (`fora_faixa = 1`) existem por categoria? (`JOIN` entre `fato_leitura_sensor` e `dim_sensor`.)
>
> *Resultado esperado:* Colhedora 69 e Trator 5. As outras categorias não aparecem, porque não têm nenhuma.
>
> **Teste você 6.3.** O laboratório tem 6 sensores com leituras de 01/02 a 31/03 (59 dias × 24 horas). Quantas linhas a fato **deveria** ter se nada tivesse sido rejeitado? Quantas ela tem? De onde vem a diferença?
>
> *Resultado esperado:* 8.496 esperadas, 8.391 reais. Faltam 105: as 60 leituras nulas e as 45 com `-999`, que o ETL mandou para a quarentena em vez de carregar.
>
> **Teste você 6.4.** Prove a granularidade: escreva uma consulta que procure mais de uma linha para a mesma combinação (`sk_tempo`, `hora`, `sk_sensor`).
>
> *Resultado esperado:* nenhuma linha.
>
> **Teste você 6.5.** Quantas leituras existem por turno (`turno` na fato)?
>
> *Resultado esperado:* Manhã 2.795, Tarde 2.797 e Noite 2.799 (os nomes saem sem acento no banco: `Manha`, `Tarde`, `Noite`).

7. Power BI: do banco ao dashboard

Slides: Dia 1, 17 · Dia 2, 6 a 12 · Estudo: 120 minutos

> **Em uma frase.** No Power BI você conecta, transforma, modela e visualiza. A parte que mais pesa não é o gráfico: é a pergunta e o modelo.

> **Antes de começar.** Os nomes de menus abaixo seguem o Power BI Desktop em português e podem variar um pouco entre versões. Se não encontrar um botão, procure pelo nome em inglês (entre parênteses) ou use a busca da barra superior.

Desktop e Service

	Power BI Desktop	Power BI Service
Para quê	Onde **se constrói** o modelo e o dashboard	Onde **se publica e se compartilha** com a empresa
No curso	Usamos o tempo todo	Só citado
Roda em	Windows	Navegador

O ciclo de trabalho tem quatro verbos: **conectar, transformar, modelar, visualizar**. Eles correspondem às três camadas do Power BI:

Camada	O que faz	Exemplo
Power Query	Conecta e transforma o dado	Mudar o tipo de uma coluna
Modelo	Relaciona fatos e dimensões	Ligar `fato_leitura_sensor` a `dim_sensor`
DAX	Calcula medidas	`% fora da faixa`

Conectar ao MySQL

1. **Página Inicial › Obter dados (*Get data*) › Banco de dados MySQL.**
2. Em **Servidor**, informe `localhost` (ou o endereço do servidor da aula). Em **Banco de dados**, `agromaq_lab`.
3. Escolha o modo **Importar**. Informe usuário e senha na aba **Banco de dados**.
4. No **Navegador**, marque as tabelas e clique em **Carregar**.

> **Pré-requisito.** O Power BI só fala com o MySQL depois de instalar o **Oracle MySQL Connector/NET**. Sem ele, a opção de conexão falha. Instale e teste antes do Dia 2.

Plano B (se o conector falhar): importe os CSVs da pasta `lab_dw_csv` por **Obter dados › Texto/CSV**, um arquivo por vez. O resto do guia funciona igual. Depois de importar, confira os tipos no Power Query: `data` precisa ser **Data**, `valor` precisa ser **Número decimal**. Se os decimais

aparecerem errados (71.5 virando 715, por exemplo), o Power BI em português está lendo o ponto como separador de milhar: no Power Query, use **Alterar tipo > Usando a localidade** e escolha **Inglês (Estados Unidos)**.

Importar ou DirectQuery? Importar copia os dados para dentro do arquivo do Power BI e é rápido; DirectQuery consulta o banco a cada clique. Na aula usamos **Importar** sobre o recorte dos alunos. Com o volume completo (2,15 milhões de leituras) seria hora de pensar em agregações e em DirectQuery.

Power Query: o ETL leve do analista

O Power Query (**Transformar dados**, *Transform data*) guarda uma lista de **passos aplicados**, na ordem em que você os fez, e repete tudo a cada atualização.

Fica no Power Query	Fica no DW
Ajuste de apresentação: renomear, ordenar, mudar tipo	Limpeza pesada e regra de negócio
Mesclar duas tabelas pequenas	Remover duplicatas e sentinelas
Filtro simples para o relatório	Calcular se uma leitura está fora da faixa

> **Pergunta-guia:** *isso cabe aqui ou deveria estar no DW?* Se a regra vale para toda a empresa, ela é do DW: assim todo relatório futuro herda o mesmo número. Se vale só para um relatório, pode ficar no Power Query.

Modelo: o DW já vem no formato certo

Abra a **Exibição de modelo** (*Model view*) e confira:

Relação	Cardinalidade	Direção do filtro
`dim_sensor[sk_sensor]` para `fato_leitura_sensor[sk_sensor]`	Um para muitos	Da dimensão para a fato
`dim_tempo[sk_tempo]` para `fato_leitura_sensor[sk_tempo]`	Um para muitos	Da dimensão para a fato

Se o Power BI detectar as relações sozinho, apenas confirme. Uma máquina, muitas leituras; a dimensão filtra a fato.

Dois ajustes que valem o minuto:

- **Tabela de datas.** Selecione `dim_tempo` e use **Ferramentas de tabela > Marcar como tabela de datas**, escolhendo a coluna `data`. Isso habilita as funções de tempo do DAX.
- **Ordem dos meses.** Selecione a coluna `nome_mes`, vá em **Ferramentas de coluna > Classificar por coluna** e escolha `mes`. Sem isso, "Fevereiro" aparece antes de "Março" só por acaso do alfabeto.

Coluna calculada ou medida?

	Coluna calculada	Medida
Quando calcula	Linha a linha, **na carga**	Na hora, quando o visual pede
Onde fica	Guardada na memória	Não ocupa linhas
Muda com o filtro	Não	**Sim**

Com milhões de linhas, **use medidas em vez de colunas**. Uma coluna nova em 2,15 milhões de linhas pesa; uma medida só é calculada para o que está na tela.

A pergunta vem antes do gráfico

> **Todo dashboard responde à pergunta de quem decide.** Escreva a pergunta **antes** de abrir o Power BI.

Exemplo da aula: *a gerente da linha de tratores quer saber se alguma máquina está saindo da faixa de operação.* A estrutura de tela que responde bem:

Posição	Conteúdo
Topo	Indicadores (cartões): os números que importam
Meio	Tendência no tempo
Embaixo	Detalhe por máquina

Qual gráfico usar

Quero mostrar	Uso
Comparar categorias	Barras
Evolução no tempo	Linhas
Composição	Barras empilhadas
Relação entre duas variáveis	Dispersão
Um valor só	Cartão

Evite: gráficos 3D, excesso de cores e eixos truncados. Pizza só com duas ou três fatias.

Use a cor para guiar o olhar

A cor é linguagem. A paleta do curso tem papéis fixos:

Cor	Hex	Significa
Sapphire	`#4059AD`	O dado normal
Emerald	`#26C485`	Meta atingida

Cor	Hex	Significa
Gold	`#F4B942`	Atenção e desvio
Ink Black	`#050517`	Texto

Um destaque por tela. Se tudo é colorido, nada chama atenção. No Power BI, use **Formatar › Cores › fx (formatação condicional)** para pintar de Gold só o que passa do limite.

> **Atenção.** Não use cor como único sinal: pessoas com daltonismo podem não distinguir. Combine com texto, ícone ou posição.

Montando o dashboard de três páginas (versão do laboratório)

Na aula, as páginas D1 a D3 usam o DW completo (fato de produção e de leitura). No laboratório, você monta a mesma estrutura com a fato de leituras. **Antes de cada página, escreva a pergunta.**

Página	Pergunta	Visuais sugeridos
1. Visão executiva	Quantas leituras temos e quantas saíram da faixa?	3 cartões (`Leituras`, `Leituras fora da faixa`, `% fora da faixa`); barras por `categoria`; segmentação por `nome_mes` e `unidade`
2. Sensores	Alguma máquina está saindo do normal?	Linhas da `Temperatura média` por `data`; filtro por `nome_maquina`; barras de `Leituras fora da faixa` em Gold quando maior que zero
3. Causa	Onde e quando as leituras saem da faixa?	Matriz `nome_maquina` por `turno` com `Leituras fora da faixa`; tabela dos maiores valores

As medidas usadas nas páginas são as do Capítulo 8. Volte aqui depois de criá-las.

> **Checkpoint, página 1:** os cartões devem mostrar **8.391**, **74** e **0,88%**.
>
> **Checkpoint, página 3:** na matriz, a máquina *Robo de Solda TIG* na coluna *Noite* mostra **69**.

Teste você

> **Teste você 7.1.** Conecte o Power BI ao banco `agromaq_lab` (ou importe os CSVs, se o conector falhar) e carregue `dim_sensor`, `dim_tempo` e `fato_leitura_sensor`.
>
> *Resultado esperado:* as 3 tabelas aparecem no painel **Dados**, com 316, 59 e 8.391 linhas.
>
> **Teste você 7.2.** No modelo, confira as duas relações um-para-muitos, marque `dim_tempo` como tabela de datas e classifique `nome_mes` por `mes`.
>
> *Resultado esperado:* um cartão com a medida `Leituras` (Capítulo 8) fatiado por `nome_mes` mostra Fevereiro antes de Março.

Teste você 7.3. Escreva, em uma frase, a pergunta que cada uma das três páginas responde. Só depois construa os visuais.

Teste você 7.4. Monte as três páginas. Use só **um destaque Gold por página**.

Resultado esperado: os checkpoints acima.

8. DAX essencial

Slides: Dia 2, 13 e 14 · Estudo: 90 minutos

> **Em uma frase.** DAX é a linguagem das medidas do Power BI. A ideia mais importante é uma só: **a mesma medida muda de valor conforme o filtro que está ativo**.

Contexto de filtro

Considere uma medida simples, `[Leituras]`, que conta as linhas da fato. Veja o que ela mostra em lugares diferentes:

Onde está a medida	O que ela calcula	Por quê
Em um cartão	Tudo (8.391)	Nenhum filtro ativo
Em uma matriz, uma linha por turno	Uma linha por vez (2.795 / 2.797 / 2.799)	Cada turno é um filtro
Com a segmentação em "Março"	Só o recorte (4.411)	O filtro do usuário entra no cálculo

Você escreve a fórmula **uma vez**; o Power BI a recalcula para cada célula do visual, com o filtro daquela célula. Entender isso é entender o DAX.

> **Separador de argumentos.** Se o seu Windows está em português do Brasil, o Power BI pode exigir **ponto e vírgula** entre os argumentos (`DIVIDE(a; b)`), em vez de vírgula. As fórmulas deste guia usam vírgula; se aparecer erro de sintaxe, troque.

As seis funções que resolvem a maior parte dos casos

Função	O que faz	Exemplo
`SUM`	Soma uma coluna	`SUM(fato[valor])`
`COUNTROWS`	Conta as linhas	`COUNTROWS(fato_leitura_sensor)`
`DIVIDE`	Divisão segura, sem erro por zero	`DIVIDE(a, b)`
`CALCULATE`	**Muda o contexto de filtro**	`CALCULATE([Leituras], turno = "Noite")`
`FILTER`	Filtra por uma condição	`FILTER(tabela, condição)`
`DATEADD`	Volta no tempo, como o mês anterior	`DATEADD(dim_tempo[data], -1, MONTH)`

`CALCULATE` é a mais poderosa: ela recalcula uma medida **mudando o filtro**. Quase toda medida interessante usa `CALCULATE`.

Para funções de tempo, a tabela de datas precisa estar **marcada como tabela de datas** (Capítulo 7).

As cinco medidas da aula (versão do laboratório)

Crie-as na tabela `fato_leitura_sensor` (**Ferramentas de tabela > Nova medida**). Na aula, a primeira é "Total produzido"; no laboratório, o equivalente é o total de leituras.

```
Leituras = COUNTROWS(fato_leitura_sensor)

Leituras fora da faixa =
CALCULATE(
    COUNTROWS(fato_leitura_sensor),
    fato_leitura_sensor[fora_faixa] = 1
)

% fora da faixa =
DIVIDE([Leituras fora da faixa], [Leituras])

Fora da faixa mês anterior =
CALCULATE(
    [Leituras fora da faixa],
    DATEADD(dim_tempo[data], -1, MONTH)
)

Variação vs mês anterior =
IF(
    ISBLANK([Fora da faixa mês anterior]),
    BLANK(),
    [Leituras fora da faixa] - [Fora da faixa mês anterior]
)
```

Formate `% fora da faixa` como **porcentagem** (**Ferramentas de medida > Formato**).

Para ver o `FILTER` em ação, uma medida do turno da noite:

```
Leituras noite =
CALCULATE(
    [Leituras],
    FILTER(fato_leitura_sensor, fato_leitura_sensor[turno] = "Noite")
)
```

Ela devolve o mesmo que `CALCULATE([Leituras], fato_leitura_sensor[turno] = "Noite")`. A forma curta é mais comum; `FILTER` ganha quando a condição é mais complexa.

> **Por que `DIVIDE` e não `/`?** `DIVIDE` devolve vazio quando o denominador é zero. A barra comum pode devolver infinito ou resultado enganoso. Em medidas de porcentagem, use sempre `DIVIDE`.

Valores esperados

Use estes valores para conferir cada medida. Eles foram calculados com SQL no mesmo DW:

Contexto	Leituras	Leituras fora da faixa	% fora da faixa
Total	8.391	74	0,88%
Fevereiro	3.980	28	0,70%
Março	4.411	46	1,04%
Turno Manhã	2.795	2	0,07%
Turno Tarde	2.797	3	0,11%
Turno Noite	2.799	69	2,47%

Na matriz por mês: `Fora da faixa mês anterior` mostra vazio em Fevereiro (não há janeiro) e **28** em Março; `Variação vs mês anterior` mostra vazio em Fevereiro e **+18** em Março (46 menos 28).

Teste você

Teste você 8.1. Crie as medidas `Leituras`, `Leituras fora da faixa` e `% fora da faixa`. Coloque as três em cartões.

Resultado esperado: 8.391, 74 e 0,88%.

Teste você 8.2. Coloque `Leituras` e `Leituras fora da faixa` em uma matriz com `turno` nas linhas. Depois ative a segmentação de `nome_mes`.

Resultado esperado: a tabela de valores esperados acima. Observe que a medida é a mesma e o resultado muda.

Teste você 8.3. Crie `Fora da faixa mês anterior` e `Variação vs mês anterior`, e mostre-as em uma matriz por `nome_mes`.

Resultado esperado: Fevereiro vazio e vazio; Março 28 e +18.

Teste você 8.4 (depurar com IA). A medida abaixo tem um defeito. Cole-a em uma IA, peça a explicação e a correção, e **confira o resultado contra o número do SQL**:

```
Leituras fora da faixa =
CALCULATE(
    COUNTROWS(fato_leitura_sensor),
    fato_leitura_sensor[fora_faixa] = 0
)
```

Resultado esperado: a medida com defeito mostra **8.317** no cartão; a correta mostra **74**. Quem confirma é o SQL (`SELECT SUM(fora_faixa) FROM fato_leitura_sensor`), não a IA. *A IA propõe, o dado confirma.*

Teste você 8.5 (desafio). Crie `% de leituras da noite` (leituras da noite divididas pelo total, com `DIVIDE`). Qual valor você espera? Confira.

Resultado esperado: 33,36% (2.799 de 8.391).

Antes de seguir. Você consegue explicar, com suas palavras, por que `% fora da faixa` dá 0,07% na linha da Manhã e 2,47% na da Noite **sem você ter escrito duas fórmulas**? Se sim, entendeu contexto de filtro.

9. IA dentro de dashboards

Slides: Dia 2, 15 e 16 · Estudo: 40 minutos

> **Em uma frase.** A IA propõe, o dado confirma. Ensinamos o padrão, não o botão.

O que o Power BI Desktop já traz

Recurso	O que faz	Bom para
Key Influencers (Principais influenciadores)	Mostra o que mais pesa em um resultado	"O que faz uma leitura sair da faixa?"
Decomposition Tree (Árvore de decomposição)	Abre o total em categorias, passo a passo	Explorar de onde vem um número
Smart Narrative (Narrativa inteligente)	Texto automático que resume o visual	Primeiro rascunho de um comentário
Q&A (Perguntas e respostas)	Perguntas em linguagem natural	Exploração rápida
Anomalias	Marca pontos fora do padrão em gráficos de linha com data	Achar o dia estranho
Quick Insights	Sugere padrões que você não procurou	Primeira olhada em um dado novo

> **Copilot é outra história.** Ele exige capacidade paga (Fabric F2 ou superior, ou Premium P1 ou superior) e ativação pelo administrador. Provavelmente **não está disponível** em máquinas de aula ou de teste. Os visuais acima, segundo o exemplo oficial de IA do Power BI, podem ser explorados no Desktop; mesmo assim, teste cada um no seu dado antes de prometer algo.

Alguns visuais precisam de volume e de tipo de dado específicos para mostrar algo útil. Se um deles não render com o seu conjunto, troque por outro e registre o motivo. Isso também é aprendizado.

Os mesmos quatro padrões aparecem em qualquer ferramenta

Padrão	O que acontece
Pergunta vira consulta	Linguagem natural vira gráfico
Narrativa automática	Texto sobre o que mudou
Detecção de anomalia	Marca o que foge do padrão
Assistente de fórmula	Escreve o SQL ou a medida

Outras plataformas de BI (Tableau, Looker, Metabase, Superset e semelhantes) têm recursos parecidos, com nomes diferentes. Confira os nomes na documentação de cada uma antes de citar. Aprenda o **padrão**, e o botão você acha em qualquer ferramenta.

Riscos

Risco	Como aparece	Defesa
Resposta fluente e errada	Texto confiante com número incorreto	Conferir com SQL ou medida
Métrica errada com cara de certa	A IA calcula o que você pediu, não o que quis dizer	Escrever a definição da métrica antes
Dado sensível no chat	Colar dado real de cliente em ferramenta pública	Não colar; no curso o dado é fictício, mas a regra vale
Dependência	Não entender o SQL ou a medida que a IA escreveu	Pedir explicação e refazer à mão uma vez

Como pedir bem

Uma boa pergunta à IA tem quatro partes: **contexto** (o schema), **tarefa** (o que fazer), **restrição** (o que não fazer) e **formato** (como responder). Exemplo:

> Tenho a tabela `fato_leitura_sensor(sk_tempo, hora, turno, sk_sensor, valor, status_leitura, fora_faixa)`. Escreva uma medida DAX para a porcentagem de leituras fora da faixa. Use `DIVIDE`. Explique cada linha em uma frase.

Depois de receber a resposta, **teste numa amostra e compare com um número que você já conhece**.

Teste você

Teste você 9.1. Com o dashboard do Capítulo 7 pronto, rode em dupla:

1. **Key Influencers** analisando `fora_faixa` (ou a medida de leituras fora da faixa), explicado por `turno`, `categoria` e `nome_maquina`.
2. **Decomposition Tree** da medida `Leituras fora da faixa`, abrindo por `categoria`, `nome_maquina` e `turno`.
3. **Detecção de anomalia** em um gráfico de linha da temperatura média por `data`.

Anote o que cada um disse. *O que você espera ver?* O turno da noite e a máquina `Robo de Solda TIG` concentram as leituras fora da faixa (69 das 74); o sensor `SEN00016` tem o pico de 12/03.

Teste você 9.2. Escolha **uma** afirmação da IA, confirme com SQL ou com uma medida DAX e conte: bateu ou não bateu?

> *Resultado esperado:* uma tabelinha com a afirmação, a consulta usada e o veredito. Insight sem número que o sustente é só opinião.

10. Ciência de dados: a base antes do modelo

Slides: Dia 2, 17 a 21 · Estudo: 90 minutos

> **Em uma frase.** O cientista parte de uma pergunta e termina em um modelo monitorado. Neste curso a ciência de dados é **teoria com exemplos na AgroMaq**: ninguém treina modelo em aula, mas todo mundo sai entendendo o caminho.

O trabalho e o método

Etapa	O que acontece
1. Pergunta de negócio	O que queremos decidir?
2. Dados	O que a engenharia entregou (o pipeline do Dia 1)
3. Exploração	Estatística e gráficos para entender o dado
4. Modelagem	Escolher e treinar um modelo
5. Validação	Medir se o modelo funciona em dado novo
6. Entrega e monitoramento	Colocar em uso e vigiar

A maior parte do tempo vai para **entender o problema e preparar o dado**, não para o modelo. E o cientista depende da engenharia: sem o pipeline de ontem, não há modelo hoje.

Quem	Pergunta	Nível
Analista	O que aconteceu?	Descritivo (e diagnóstico)
Cientista	O que vai acontecer? O que fazer?	Preditivo e prescritivo

Quatro áreas da matemática

Sem fórmulas pesadas. A ideia de cada área e onde ela aparece:

Área	Para que serve	Na AgroMaq
Estatística descritiva	Resumir: média, mediana, desvio, percentis	Faixa normal de temperatura de um sensor
Probabilidade e inferência	Medir incerteza; separar ruído de sinal	Uma leitura alta é pico legítimo ou falha?
Álgebra linear	Dados como vetores e matrizes	Cada máquina descrita por um vetor de sensores
Cálculo e otimização	Treinar modelos minimizando o erro	“Descer a ladeira” do erro de previsão

Conceitos de modelagem

Conceito	Em uma frase
Aprendizado supervisionado	Existe resposta conhecida (por exemplo, “falhou” ou “não falhou”) e o modelo aprende a prevê-la
Aprendizado não supervisionado	Não há resposta; o modelo descobre grupos ou anomalias
Treino e teste	Separe parte do dado para ensinar e parte, **que o modelo nunca viu**, para avaliar
Overfitting	Decorar o treino em vez de aprender o padrão: vai bem no treino e mal no mundo real
Métricas	Dependem do problema (acurácia, precisão, recall, erro médio…)
Vazamento de dados	Deixar entrar no treino uma informação que só existiria depois do fato

> **A armadilha da acurácia.** Peça a uma IA “preveja falha” e ela pode devolver um modelo com **99% de acurácia**, só porque quase nunca há falha: um modelo que responde “nunca falha” acerta quase tudo e não serve para nada. Você vai medir isso no Teste 10.3.

Cinco problemas da fábrica que viram ciência de dados

Problema	Tipo	Dado	Pergunta de negócio
Prever falha de máquina	Classificação (supervisionado)	Leituras de sensor + histórico de paradas	Qual máquina deve parar nos próximos dias?
Detectar comportamento anormal	Anomalia (não supervisionado)	Leituras de sensor por hora	O que foge do padrão da própria máquina?
Prever demanda	Séries temporais	Vendas e produção por mês	Quantos tratores produzir no próximo trimestre?
Segmentar clientes	Agrupamento	Clientes por país, mercado e volume	Existem perfis de cliente distintos?
Achar causas de refugo	Importância de variáveis	Produção + motivos de não conformidade	Que fatores mais pesam no refugo?

O **Key Influencers** que você usou no Capítulo 9 é o primo simples do último problema.

Cargos vizinhos

Cargo	Foco	Ferramentas comuns
Analista de dados	Responder perguntas, dashboards	SQL, Power BI, Excel

Cargo	Foco	Ferramentas comuns
Engenheiro de dados	Pipelines, qualidade, DW	SQL, Python, nuvem
Engenheiro de analytics	Modelagem para análise	SQL, dbt
Cientista de dados	Modelos e experimentos	Python, pandas, scikit-learn
Engenheiro de ML	Modelo em produção	Python, MLOps, nuvem
Engenheiro de IA	Aplicações com modelos de linguagem	APIs de LLM, RAG, Python

A fronteira entre cientista e engenheiro de IA está se movendo (KDnuggets, jan/2026), e os títulos variam de empresa para empresa. O **scikit-learn** é a biblioteca de modelos clássicos em Python; PyTorch e TensorFlow são as de deep learning. Você já usou pandas e NumPy; as outras aparecem aqui só como referência.

Mercado, certificações e IA

Tema	O que se sabe	Fonte
Vagas no Brasil	Mais de 100 mil vagas de dados	Alura, com base no State of Data
Faixas salariais	Júnior R$ 3 a 5 mil; pleno R$ 5 a 9 mil	Glassdoor, citado pela Alura
Trabalho remoto	40 a 50% das vagas remotas ou híbridas	Alura
Referência EUA	Cientista de dados: mediana perto de US$ 170 mil; engenheiro de IA: acima de US$ 200 mil	Levels.fyi e Built In, via KDnuggets

> **Não transponha os números dos EUA para o Brasil.** Use-os só como referência de tendência. As faixas do Brasil são ordem de grandeza e mudam com cidade, setor e porte da empresa.

Sobre **IA na ciência de dados**: assistentes escrevem código de exploração, sugerem variáveis e explicam resultados, mas o cientista continua dono da **pergunta, da métrica e da interpretação**. O risco é aceitar um modelo "que funciona" sem entender a métrica ou o vazamento de dados. A base (estatística, pensamento crítico, dado bem preparado) vale mais que a ferramenta da moda.

Teste você

Estes testes usam os CSVs do DW do laboratório. Monte a tabela completa em pandas:

```
import pandas as pd

fato   = pd.read_csv("lab_dw_csv/fato_leitura_sensor.csv")
sensor = pd.read_csv("lab_dw_csv/dim_sensor.csv")
tempo  = pd.read_csv("lab_dw_csv/dim_tempo.csv", parse_dates=["data"])

d = fato.merge(sensor, on="sk_sensor").merge(tempo, on="sk_tempo")
d.shape        # (8391, 23)
```

Teste você 10.1 (estatística descritiva). Calcule contagem, média, desvio, mínimo e máximo de `valor` por `codigo_sensor`.

Resultado esperado: `SEN00104` tem média 90,31 e máximo 97,8 (o mais quente); `SEN00016` tem média 72,11 e **máximo 121,3**, muito acima do resto da própria série.

Teste você 10.2 (ruído ou sinal). Para o sensor `SEN00016`, encontre os valores atípicos de duas formas: pela regra dos **3 desvios** e pela regra do **IQR** (valores abaixo de Q1 − 1,5 × IQR ou acima de Q3 + 1,5 × IQR). Os dois métodos concordam?

Resultado esperado: limites do IQR de 61,75 e 82,15; os dois métodos marcam as **mesmas 5 leituras** (98,4 / 105,2 / 112,7 / 118,9 / 121,3). A estatística acha o suspeito; decidir se é falha ou aviso é com o negócio.

Teste você 10.3 (a armadilha da acurácia). Crie uma "previsão" que diz sempre "dentro da faixa" (`fora_faixa = 0`). Calcule a acurácia e o *recall* (de todas as leituras fora da faixa, quantas o modelo achou?).

Resultado esperado: acurácia de **99,12%** e recall de **0%**. O modelo "acerta" quase tudo e não detecta nada.

Teste você 10.4 (o que explica o resultado). Para o sensor `SEN00104`, calcule a média de `valor` e a soma de `fora_faixa` por `turno`. Qual variável explica as leituras fora da faixa?

Resultado esperado: médias de 88,23 (Manhã), 93,65 (Noite) e 89,03 (Tarde); as 69 leituras fora da faixa estão todas na Noite. É o mesmo raciocínio do Key Influencers.

Teste você 10.5 (reflexão). Dos cinco problemas da tabela, qual é supervisionado? Qual precisa de histórico de paradas que o laboratório **não** tem? Por que o vazamento de dados é um risco no problema de prever falhas?

11. Insights: do número à ação

Slides: Dia 2, 22 · Estudo: 30 minutos

> **Em uma frase.** Um insight liga o número à ação. Sem número que o sustente, é só opinião; sem ação sugerida, é só curiosidade.

A estrutura em três partes

Parte	Pergunta	Exemplo
O que vimos	Qual é o fato, com o número?	O refugo da Linha X sobe no turno da noite
Por que importa	Qual é o efeito no negócio?	Aumenta o custo e atrasa a entrega
O que fazer	Qual é o próximo passo?	Revisar a calibração da máquina Y

Modelo para decorar: **vimos X (número), importa porque Y, sugerimos Z.**

Fraco e forte

	Exemplo	Por que
Fraco	"O refugo é 4%."	Um número solto, sem contexto nem ação
Forte	"O refugo da Linha X sobe no turno da noite; sugerimos revisar a calibração da máquina Y."	Tem o fato, a causa provável e o próximo passo

Os dois exemplos são ilustrativos e não vêm dos dados reais da AgroMaq.

Exemplo com os dados do laboratório

Veja como seriam três insights escritos a partir do dashboard do laboratório:

#	O que vimos (com número)	Por que importa	O que fazer
1	69 das 74 leituras fora da faixa (93%) vêm do sensor `SEN00104`, no Robô de Solda TIG, e **todas** no turno da noite	Operar acima de 95 °C só à noite sugere um problema de carga ou de resfriamento noturno	Investigar a rotina e a ventilação da máquina no turno da noite
2	A temperatura média desse sensor é de 93,7 °C na Noite contra 88,2 °C na Manhã: a cerca de 1,4 °C do limite	A margem de segurança à noite é pequena	Definir um alerta antes de 95 °C
3	Em 12/03, o sensor `SEN00016` passou de 98 para 121 °C em três horas e voltou ao normal	Pode ter sido uma falha evitada ou um problema de leitura	Cruzar a data com o histórico de paradas da Furadeira CNC

Repare que cada linha tem **um número**, **uma consequência** e **uma ação**. E repare no cuidado: o insight 3 termina em "cruzar com o histórico", não em uma conclusão, porque os dados do laboratório não permitem afirmar a causa.

> **Não afirme mais do que o dado permite.** "Sugerimos investigar" é um insight honesto. "A máquina vai quebrar" só é possível com um modelo validado e histórico de paradas.

Como apresentar em um minuto

1. Comece pelo **número** ("69 de 74").
2. Diga **por que importa** em uma frase.
3. Termine com a **ação** que você quer que alguém tome.
4. Se perguntarem "de onde vem o número?", mostre a consulta ou a medida.

Teste você

> **Teste você 11.1.** Olhando o seu dashboard, escreva **três insights** no formato *vimos X (número), importa porque Y, sugerimos Z.*
>
> *Resultado esperado:* três linhas, cada uma com um número que você consegue **conferir** no dashboard ou no SQL.
>
> **Teste você 11.2.** Escolha um dos seus três insights e apresente-o em voz alta, em um minuto, para alguém. Cronometre.
>
> **Teste você 11.3.** Reescreva o insight fraco "a temperatura média é 76,7 °C" até ficar forte, usando só o que o laboratório permite afirmar.

12. Carreira e próximos passos

Slides: Dia 2, 21 e 23 · Estudo: 20 minutos

O caminho que você percorreu

Dado bruto, pipeline, data warehouse, dashboard, insight. Cada etapa foi de alguém, e a decisão final só é boa se todas estiverem boas.

Trilhas e certificações iniciais

Trilha	Certificação	O que cobre
Análise	**PL-300** (Microsoft Power BI Data Analyst)	Power BI, SQL e DAX
Análise e engenharia no Fabric	**DP-600**	Modelagem e análise no Microsoft Fabric
Engenharia no Fabric	**DP-700**	Pipelines e engenharia de dados no Fabric (atualização da versão em inglês em 19/out/2026)
Engenharia em outras nuvens	**AWS Data Engineer Associate (DEA-C01)**, **Databricks Data Engineer Associate**, **Google Professional Data Engineer**	Engenharia de dados em AWS, Databricks e Google Cloud

> **Confira antes de se inscrever.** Nomes, preços e exigências de certificação mudam. Veja a página oficial de cada uma. Para ciência de dados e machine learning, existem trilhas nas três nuvens; confirme nome e situação atual na página do fornecedor.

O que estudar depois, em ordem

1. **SQL de verdade.** Faça os exercícios do Capítulo 3 de novo, sem consultar, e depois aprenda funções de janela.
2. **Power BI com um dado seu.** Um projeto pessoal vale mais que dez vídeos.
3. **Estatística básica.** Distribuições, intervalo de confiança, teste de hipótese.
4. **Python e pandas.** Primeiro análise e visualização; só depois modelos.
5. **Um modelo simples.** Quando a base estiver sólida, o scikit-learn.

Perguntas para pensar

- O que mais quebra no mundo real?
- O que você deixaria a IA fazer sozinha, e o que você sempre conferiria?

- Qual dos três perfis (analista, engenheiro, cientista) combina mais com o seu jeito de pensar?

> **A mensagem final.** A base (estatística, pensamento crítico, dado bem preparado) vale mais que a ferramenta da moda. Ferramentas mudam a cada ano; quem entende o dado muda de ferramenta sem sofrer.

Apêndice A. Montando o laboratório

Tempo estimado: 40 a 60 minutos na primeira vez.

Arquivos do laboratório

Arquivo	Para quê
`leituras_lab.csv`	O CSV com defeitos plantados (8.626 linhas)
`lab_dw_pronto.sql`	O DW de laboratório pronto, para importar no MySQL
`lab_dw_csv/`	As mesmas tabelas do DW em CSV (plano B do Power BI e do pandas)
`02_schema.sql` e `03_populacao_base.sql`	O banco `agromaq_industrial` (fornecidos pelos instrutores)

Passo a passo

1. Instale o MySQL 8 e o MySQL Workbench. Anote a senha do usuário `root`.

2. Crie o banco da AgroMaq. Pelo Workbench, abra `02_schema.sql` (*File › Open SQL Script*), execute (raio), depois abra e execute `03_populacao_base.sql`. Ou, pelo terminal:

```
mysql -u root -p < 02_schema.sql
mysql -u root -p agromaq_industrial < 03_populacao_base.sql
```

3. Confira.

```
USE agromaq_industrial;
SELECT COUNT(*) FROM maquina;   -- 120
SELECT COUNT(*) FROM sensor;    -- 316
```

4. Importe o DW do laboratório.

```
mysql -u root -p < lab_dw_pronto.sql
```

Confira:

```
USE agromaq_lab;
SELECT COUNT(*) FROM fato_leitura_sensor;   -- 8391
```

5. Prepare o Python. Instale o Python 3.11 ou mais novo. Em um terminal, dentro da pasta do laboratório:

```
python -m venv .venv
.venv\Scripts\activate          (Windows)
```

```
pip install pandas
python -c "import pandas; print(pandas.__version__)"
```

A versão deve começar com `3`. Opcionalmente: `pip install sqlalchemy pymysql matplotlib`.

6. Power BI. Instale o Power BI Desktop e o Oracle MySQL Connector/NET. Teste: **Obter dados › Banco de dados MySQL**, servidor `localhost`, banco `agromaq_lab`.

Se algo der errado

Sintoma	Causa provável	O que fazer
`Access denied`	Senha ou usuário errados	Use o usuário `root` e a senha da instalação
`Unknown database 'agromaq_lab'`	O passo 4 não rodou	Execute `lab_dw_pronto.sql`
Power BI não lista "MySQL" ou dá erro de driver	Falta o Connector/NET	Instale o conector e **reinicie** o Power BI
Nada funciona no Power BI	Firewall ou política da máquina	Plano B: importe os CSVs de `lab_dw_csv/`
`FutureWarning` ou `ChainedAssignmentError` no pandas	Código de versão antiga	Use `.loc` (Capítulo 4)
Acentos estranhos no CSV	Codificação	Os arquivos estão em UTF-8; abra como UTF-8

Apêndice B. Glossário

Termo	Significado
BI	*Business Intelligence*: o caminho do dado até a decisão
Chave natural	O código que vem do sistema de origem
Chave substituta	Número criado pelo DW para ligar fato e dimensão
CSV	Arquivo de texto com colunas separadas por vírgula
DAX	Linguagem de medidas do Power BI
Dado sentinela	Código (como `-999`) no lugar de um valor
Data warehouse (DW)	Banco organizado para análise, com fatos e dimensões
Dimensão	Tabela que descreve o contexto: quando, onde, quem
ELT	Carrega o dado bruto e trata dentro do destino
ETL	Extrai, transforma e carrega, tratando antes de entrar no destino
Fato	Tabela do que aconteceu, com números
Granularidade	O que uma linha da fato representa
Idempotência	Rodar duas vezes dá o mesmo resultado que rodar uma
Medida	Cálculo do Power BI que reage ao filtro
Modelo estrela	Fato no centro, dimensões ao redor
Nulo	Valor ausente (`NULL`, vazio, `NaN`)
OLAP	Banco feito para analisar
OLTP	Banco feito para operar o dia a dia
Órfão	Registro que aponta para algo que não existe
Overfitting	Modelo que decorou o treino e não generaliza
Pipeline	A cadeia que leva o dado da origem ao destino
Power Query	O ETL leve do Power BI
Quarentena	Tabela onde ficam as linhas rejeitadas, com o motivo
Staging	Área de entrada do dado bruto, antes do tratamento
Vazamento de dados	Informação do futuro entrando no treino do modelo

Apêndice C. Cola rápida

Quero	SQL	pandas
Contar linhas	`SELECT COUNT(*) FROM t;`	`len(df)` ou `df.shape`
Espiar	`SELECT * FROM t LIMIT 5;`	`df.head()`
Contar por grupo	`... GROUP BY col`	`df.groupby("col").size()`
Nulos	`col IS NULL`	`df["col"].isna()`
Duplicatas	`GROUP BY k HAVING COUNT(*) > 1`	`df.duplicated(subset=["k"])`
Ligar tabelas	`JOIN ... ON`	`df.merge(outro, on="k")`
Corrigir valor	`UPDATE ... SET ... WHERE`	`df.loc[cond, "col"] = valor`

Quero (DAX)	Fórmula
Contar linhas	`COUNTROWS(tabela)`
Dividir com segurança	`DIVIDE(a, b)`
Mudar o filtro	`CALCULATE([medida], tabela[col] = "x")`
Mês anterior	`CALCULATE([medida], DATEADD(dim_tempo[data], -1, MONTH))`