Materiais de Estudo e Roteiro de Slides – Engenharia de Dados (Infoeste)

Oct 10, 2026 · @TI

Plano de estudo: de 10/10 até a aula

Faltam 17 dias para o Dia 1. Com cerca de 1 hora por dia, dá para chegar seguro; a ordem vai do que você já controla (SQL) para o que é novo (pandas e arquitetura).

Período	Foco	Meta ao final	Material
10 a 16/10	SQL e modelagem dimensional	Explicar fato × dimensão e escrever um JOIN com GROUP BY sem consultar	Learning SQL; Kimball (cap. 1 a 3); consultas do 04_consultas_validacao.sql
10 a 16/10	Python e pandas básico	Ler um CSV, filtrar linhas e tratar nulos em um DataFrame	Python for Data Analysis (cap. 5 a 7); documentação do pandas
17 a 23/10	Projeto na prática	Rodar gerar_leituras.py e etl.py do início ao fim, duas vezes, sem erro	Pasta curso_eng_dados; Guia do Instrutor
17 a 23/10	Visão de mercado	Explicar ETL × ELT e o ciclo de vida do dado com suas palavras	Fundamentals of Data Engineering (cap. 1 a 3); artigos de Beauchemin
24 a 26/10	Slides e ensaio	Passar o Dia 1 em 55 minutos cronometrados e o Dia 2 em 55	Roteiro de slides deste documento
27 e 28/10	Aulas	Ensinar com segurança e anotar as dúvidas para a próxima turma	Guia do Instrutor impresso ou em segunda tela

Regra de ouro: você não precisa saber tudo, só precisa saber mais que os alunos sobre o que vai ensinar e ser honesto no resto. Prepare uma resposta pronta para "não sei, vou pesquisar e retorno amanhã".

Livros

Se puder comprar só um, leia Fundamentals of Data Engineering: é a melhor visão geral da profissão e casa com o Dia 1 inteiro. Os outros são para aprofundar por tema.

Livro	Autor e edição	Para que serve	O que ler primeiro
Fundamentals of Data Engineering	Joe Reis e Matt Housley, O'Reilly, 2022	Visão completa: ciclo de vida do dado, arquitetura, armazenamento, ingestão, transformação	Cap. 1 a 3 (o que é a profissão e o ciclo de vida)
Designing Data-Intensive Applications, 2ª ed.	Martin Kleppmann e Chris Riccomini, O'Reilly, 2026	Base teórica de bancos, armazenamento, processamento em lote e streaming; nível intermediário a avançado	Cap. sobre modelos de dados e sobre armazenamento (leitura seletiva)
The Data Warehouse Toolkit, 3ª ed.	Ralph Kimball e Margy Ross, Wiley, 2013	Referência da modelagem dimensional (fato, dimensão, star schema)	Cap. 1 e 2
Python for Data Analysis, 3ª ed.	Wes McKinney, O'Reilly, 2022	Pandas escrito pelo criador da biblioteca	Cap. 5 (começando com pandas) e 7 (limpeza de dados)
Data Pipelines Pocket Reference	James Densmore, O'Reilly, 2021	Guia curto de ETL/ELT, ingestão e orquestração; bom para uma leitura rápida	Cap. 1 a 3
Learning SQL, 3ª ed.	Alan Beaulieu, O'Reilly, 2020	Reforçar SQL (joins, agrupamentos, subconsultas)	Cap. 3 a 8

A 2ª edição do Designing Data-Intensive Applications saiu em 2026, e a página do próprio Kleppmann traz os detalhes. As demais edições vêm do meu conhecimento prévio, então confira a edição vigente na loja antes de comprar; vale ver também se há tradução para o português.

Artigos e leituras online

Os três primeiros são de Maxime Beauchemin, criador do Apache Airflow, e são a leitura mais citada para quem começa na área. Todos estão em inglês e cabem em uma noite cada.

Leitura	Por que ler	Slide da aula
The Rise of the Data Engineer (Beauchemin, 2017)	Artigo que descreve o surgimento da profissão e como ela se diferencia de BI e ciência de dados	Dia 1, slides 2 e 3
The Future of the Data Engineer (Beauchemin e Gavish, Monte Carlo)	Como o papel mudou com a nuvem e a confiabilidade de dados	Dia 1, slide 14 (carreira)
Functional Data Engineering: a set of best practices (palestra de Beauchemin)	Fundamenta a ideia de pipelines reproduzíveis, a base da idempotência que você ensina	Dia 1, slide 10; Dia 2, slide 5
Dimensional Modeling Techniques (site do Kimball Group)	Resumo gratuito das técnicas de modelagem dimensional; busque o título no site	Dia 1, slides 11 e 12

Para apresentar ao vivo, as ideias de Beauchemin viram boas frases de abertura: ele argumenta que o engenheiro de dados se aproxima mais da engenharia de software do que da ciência de dados, e que o data warehouse é o centro do trabalho.

Cursos gratuitos e documentação oficial

A documentação oficial é a fonte mais confiável e a que profissionais consultam todo dia; acostumar os alunos a ela é parte da aula.

Recurso	Endereço	Para que serve
Data Engineering Zoomcamp (DataTalksClub)	github.com/DataTalksClub/data-engineering-zoomcamp	Curso gratuito e prático de engenharia de dados; ótimo como próximo passo indicado aos alunos
Documentação do pandas	pandas.pydata.org	Consultar read_csv, to_sql, drop_duplicates e demais funções do etl.py

Recurso	Endereço	Para que serve
Documentação do SQLAlchemy	docs.sqlalchemy.org	Entender create_engine e as conexões
MySQL Reference Manual	dev.mysql.com/doc	Consultar tipos de dados, índices, chaves estrangeiras e funções
Apache Airflow	airflow.apache.org	Próximo passo: agendar o ETL automaticamente
dbt	docs.getdbt.com	Próximo passo: transformações em SQL dentro do DW (ELT)

Os endereços acima são dos sites oficiais; só os links das seções anteriores foram verificados por busca.

Princípios para montar os slides

A aula é à noite e depois de um dia de trabalho, então slides leves e visuais seguram a atenção melhor que texto corrido. Use estas regras como padrão em todos os slides.

Regra	Como aplicar
Uma ideia por slide	O título já é a conclusão (por exemplo, "Dado real chega sujo"), não um tema ("Qualidade de dados")
Pouco texto	Máximo de 4 linhas curtas; o detalhe vai na sua fala e nas anotações do apresentador
Diagrama antes de lista	Setas e caixas para fluxos (ciclo de vida, pipeline); tabela só para comparação
Código legível	Trechos de até 12 linhas, fonte monoespaçada grande, destaque na linha que importa; o arquivo completo fica no repositório
Uma história única	Use o AgroMaq (fábrica, tratores, sensores) em todos os exemplos para criar continuidade
Cores com função	Origem em uma cor, destino em outra, erro em vermelho; mantenha o mesmo código de cores nos dois dias

Regra	Como aplicar
Contraste e tamanho	Fundo escuro ou claro com texto de alto contraste; corpo com pelo menos 24 pt, código com pelo menos 18 pt
Anotações do apresentador	Escreva ali a frase de abertura, a analogia e a pergunta que fará à turma
Interação	A cada 10 a 15 minutos, uma pergunta para a turma ("onde isso dá erro?")

Ferramenta: qualquer uma serve (PowerPoint, Google Slides, Canva). Use as anotações do apresentador do próprio programa para colar as falas do Guia do Instrutor.

Roteiro de slides do Dia 1: Conceito (14 slides, 60 min)

Com uma hora, cada slide cobre um bloco inteiro; a coluna "Fontes" indica a seção da Biblioteca de Fontes que alimenta aquele slide.

Nº	Título do slide	Visual	Fala-chave	Min	Fontes
1	Introdução à Engenharia de Dados	Capa e linha do tempo: Dia 1 conceito, Dia 2 prática	Apresentação, objetivo e combinado do curso	2	
2	Três papéis, um objetivo: dado confiável	Três colunas (engenheiro, analista, cientista) com o engenheiro em destaque	O engenheiro entrega o dado; os outros dois o consomem	4	Abertura e mercado
3	Por que a demanda cresce	Ícones: mais sistemas, mais dados, mais decisões; cena de pipeline quebrado	Dado virou produto e alguém precisa mantê-lo confiável	3	Abertura e mercado
4	O ciclo de vida do dado	Diagrama horizontal de 5 etapas	Este é o mapa do curso; volte a ele nos slides seguintes	5	Ciclo de vida e OLTP × OLAP
5	Nosso caso: AgroMaq, OLTP × OLAP	Fábrica com sensores IoT; duas colunas (caixa do supermercado × sala de relatórios)	Um banco para operar, outro para analisar	6	Ciclo de vida e OLTP × OLAP
6	Onde o dado mora	Cinco ícones: relacional, NoSQL, warehouse, lake, lakehouse, com um exemplo de ferramenta cada	Escolha conforme formato e uso do dado	6	Armazenamento

Nº	Título do slide	Visual	Fala-chave	Min	Fontes
7	CSV, JSON e Parquet	Mesmo dado em três formatos, com tamanhos comparados	Parquet é colunar e compacto	3	Armazenamento
8	ETL × ELT	Dois fluxos lado a lado, com a etapa T em posições diferentes	Onde a transformação acontece; ETL não morreu	5	Pipelines
9	Batch × streaming e orquestração	Esteira em lotes × fluxo contínuo; relógio com alerta e logo do Airflow	Quando o dado precisa chegar na hora e quem agenda e vigia o pipeline	5	Pipelines
10	Rodar duas vezes não pode duplicar	Elevador com botão apertado 5 vezes; cartão de transação; lista de defeitos (nulo, duplicado, outlier, órfão)	Idempotência, transação e qualidade: o que o Dia 2 vai provar	6	Pipelines
11	Fato e dimensão	Cupom fiscal (fato) ligado ao cadastro (dimensão)	Fato registra eventos; dimensão descreve os participantes	4	Modelagem dimensional
12	O modelo que vamos construir	Star schema: fato_leitura_sensor no centro e dim_sensor ao lado	Este é o destino do ETL do Dia 2	5	Modelagem dimensional
13	Mapa das ferramentas	Tabela por camada, com o gráfico de frequência das vagas	Não precisa saber tudo, só o que cada camada resolve	3	Ferramentas e carreira
14	Carreira, trilha e preparação do Dia 2	Escada: SQL, Python, nuvem, Airflow, dbt, Spark; checklist de instalação	Por onde começar; o que instalar antes do Dia 2	3	Ferramentas e carreira

Se atrasar, corte nesta ordem: o slide 3 e o slide 7 (juntos liberam 6 minutos), depois reduza o slide 6 a um quadro único.

Roteiro de slides do Dia 2: Prática (8 slides, 60 min)

Para caber em uma hora, a preparação precisa acontecer antes da aula: os alunos chegam com Python, MySQL e bibliotecas instalados, e você já rodou o 05_dw_agromaq.sql e o gerar_leituras.py (o CSV sujo fica pronto na pasta). Em aula só se lê, trata e carrega.

Nº	Título do slide	Visual	O que fazer ao vivo	Min
1	Mão na massa: o pipeline que vamos construir	Diagrama: MySQL e CSV → etl.py → data warehouse, com rejeitos saindo para o lado	Recap rápido do Dia 1 e teste de conexão de cada aluno	4
2	Fonte e destino	Prints de 2 consultas do 04_consultas_validacao.sql e do star schema já criado	Mostrar por que o OLTP não serve para análise e as tabelas do DW	6
3	E: Extract	Trecho de 10 linhas da função extract, com o read_sql em destaque	Abrir o CSV sujo e inspecionar com .info(), .describe() e .isna().sum()	9
4	T: Transform	Tabela de 7 linhas: defeito do CSV × tratamento aplicado	Comentar o transform regra por regra e rodar até ver o log	15
5	L: Load	Diagrama da transação (DELETE, INSERT, commit) com a palavra "idempotente" em destaque	Explicar o with DW.begin() e rodar a carga	8
6	O dado virou informação	Resultado das consultas do 06_consultas_dw.sql e duas contagens iguais lado a lado	Rodar 2 das 4 consultas e depois o etl.py pela segunda vez, comparando a contagem	10
7	Em produção seria assim	Pipeline com Airflow agendando e dbt transformando	Mostrar onde Airflow, dbt e Spark entrariam	4
8	Próximos passos e desafio	Escada de estudo, desafio da dim_produto e links de documentação	Indicar o Zoomcamp, pedir feedback e encerrar	4

Parada de segurança: no slide 4, aos 8 minutos, se a turma estiver atrasada, entregue o transform completo e vá direto ao load.

Checklist de produção e ensaio

Use a lista na ordem: produzir os slides leva umas 3 a 4 horas, e o ensaio é o que mais aumenta a sua segurança.

- [ ] Escolher a ferramenta e criar um modelo com cores, fontes e o logo da Infoeste
- [ ] Montar os 14 slides do Dia 1 e os 8 do Dia 2 seguindo as tabelas acima
- [ ] Desenhar os 4 diagramas principais: ciclo de vida, OLTP × OLAP, star schema e pipeline do Dia 2
- [ ] Colar a fala-chave de cada slide nas anotações do apresentador
- [ ] Tirar prints reais das consultas e do log do ETL depois de rodar o projeto
- [ ] Colocar o código em fonte grande, com a linha principal destacada
- [ ] Ensaiar o Dia 1 cronometrado (meta: 55 minutos) e marcar os slides que podem ser cortados
- [ ] Ensaiar o Dia 2 cronometrado (meta: 55 minutos), incluindo a execução real do ETL
- [ ] Preparar plano B: PDF dos slides, projeto já executado e prints dos resultados
- [ ] Enviar a pasta curso_eng_dados e o checklist de pré-requisitos aos alunos antes de 28/10
- [ ] Testar projetor, internet e o MySQL na sala, se possível no dia anterior