# Roteiro de Conteúdo — Além do Código (Infoeste 2026)

Oct 10, 2026 · @Galindo

## Visão geral

São dois encontros noturnos de 4 h (3 h 50 de conteúdo e 10 min de intervalo) para iniciantes de TI e de negócios, conduzidos por uma única história: a fábrica de máquinas agrícolas AgroMaq. O Dia 1 vai do dado bruto ao dado confiável; o Dia 2 vai do dado confiável à decisão.

| Tema | Decisão fechada |
|---|---|
| Formato | 2 noites de 4 h, até 25 alunos, máquinas Windows da instituição |
| Fio condutor | Banco `agromaq_industrial`: 38 tabelas, 2 unidades, 120 máquinas, 316 sensores |
| Período dos dados | Leituras de 01/01/2026 a 10/10/2026, 1 por hora (cerca de 2,15 milhões) |
| Prática dos alunos | Trabalham com um recorte do volume completo |
| Dado sujo | Gerado por nós em Python, com seed fixa e gabarito; o banco original não é alterado |
| Modelo dimensional | 2 fatos (leitura de sensor e produção); vendas ficam como desafio |
| Ferramentas | MySQL, Python (pandas, SQLAlchemy e outras), Power BI Desktop |
| IA | Atravessa análise, engenharia e ciência; os alunos usam IA gratuita no navegador |
| Ciência de Dados | Teoria com exemplos aplicados ao dataset, sem rodar modelos |

## Design: a paleta e o papel de cada cor

A paleta tem quatro cores com papéis fixos, iguais nos dois dias, e cada par de texto e fundo foi medido (razão de contraste WCAG, calculada por mim num script local).

| Cor | Hex | Papel nos slides | Texto que pode ir sobre ela |
|---|---|---|---|
| Ink Black | #050517 | Texto principal, caixas de código e botões de destaque | Dentro das caixas de código: branco #EDF2F4 |
| Sapphire | #4059AD | Origem do dado: fontes, CSV, banco operacional | Branco (6,5:1) |
| Emerald | #26C485 | Destino e sucesso: DW, dado tratado, "passou" | Ink Black (9,0:1) |
| Sunflower Gold | #F4B942 | Destaque, atenção e defeito | Ink Black (11,4:1) |

Regras que saem das medidas:

- Texto sobre Emerald e sobre Gold é sempre Ink Black. Branco falha nos dois (2,3:1 e 1,8:1).
- Sapphire sobre Ink Black dá só 3,1:1, então serve para caixas grandes com texto branco dentro, nunca para texto fino.
- Gold sobre Sapphire (3,7:1) e Emerald sobre Sapphire (2,9:1) servem para formas grandes, não para texto.
- A paleta não tem vermelho. Defeito e erro usam Gold com um ícone de alerta, para que o sentido não dependa só da cor.
- Fluxos: origem em Sapphire, destino em Emerald, rejeitos em Gold saindo para o lado.

**Decisão de tema (projetor):** fundo claro #EDF2F4 nos slides de conteúdo, para não pesar no projetor. Emerald fica como fundo da capa, das transições e do intervalo, com texto Ink Black. Emerald e Gold só aparecem como preenchimento, nunca como cor de texto sobre fundo claro. Caixas de código em Ink Black. Fontes: Bricolage Grotesque nos títulos, Manrope no texto e JetBrains Mono no código.

## Dia 1: do dado bruto ao dado confiável

O Dia 1 usa 230 min para levar o aluno do "o que é BI" até o dado tratado no banco, e a prática de 85 min é o centro da noite. Os slides têm o título escrito como conclusão, não como tema.

| # | Bloco | Título do slide | Min | Visual e fala-chave |
|---|---|---|---|---|
| 1 | Abertura | Dados viram decisão quando alguém os torna confiáveis | 3 | Capa com a linha do tempo dos 2 dias. Apresentação, objetivo e combinados |

| # | Bloco | Título do slide | Min | Visual e fala-chave |
|---|---|---|---|---|
| 2 | Abertura | Hoje o cliente é a AgroMaq | 4 | Mapa das 2 unidades (Presidente Prudente e Três Lagoas), 120 máquinas e 316 sensores. Pergunta: quem já viu um relatório com número errado? |
| 3 | Abertura | O que vocês levam daqui | 3 | Checklist dos 2 dias: dado sujo, ETL, modelo, dashboard, IA |
| 4 | Dados e BI | Toda empresa produz dado, poucas o usam | 5 | Ícones de ERP, sensores e vendas apontando para decisões. Dado como ativo |
| 5 | Dados e BI | BI é o caminho do dado até a decisão | 7 | Diagrama: fontes, integração, armazenamento, análise, decisão. Cada etapa com um exemplo da fábrica |
| 6 | Dados e BI | A mesma pergunta tem três níveis de resposta | 5 | Escada descritiva, preditiva e prescritiva: "quanto produzimos?", "qual máquina vai falhar?", "o que fazer?" |
| 7 | Dados e BI | Dado vira informação e depois conhecimento | 3 | Uma leitura de sensor virando uma decisão de manutenção |
| 8 | Profissões | Três profissões, um objetivo: decisão confiável | 5 | Três colunas (analista, engenheiro, cientista) e uma linha sobre o analytics engineer |
| 9 | Profissões | O analista responde perguntas com dados | 5 | Rotina, ferramentas (SQL, Excel, Power BI) e entregável. Exemplo: refugo por linha |
| 10 | Profissões | O engenheiro garante que o dado exista e seja confiável | 6 | Rotina e ferramentas. Exemplo: leituras de sensor chegando duplicadas |
| 11 | Profissões | O cientista prevê e descobre padrões | 4 | Pincelada; o detalhe fica para o Dia 2 |

| # | Bloco | Título do slide | Min | Visual e fala-chave |
|---|---|---|---|---|
| 12 | Profissões | No mesmo problema, os três trabalham em sequência | 5 | Fluxo: máquina parou, engenheiro (dado), analista (causa), cientista (previsão) |
| 13 | Ferramentas | Cada camada do dado tem sua ferramenta | 6 | Mapa por camada: MySQL, SQL, Python, Power BI; Airflow, dbt, Spark e nuvem como próximos passos |
| 14 | Ferramentas | SQL é a língua comum de todas as profissões | 6 | Um `SELECT` com `JOIN` e `GROUP BY` sobre máquina e linha do AgroMaq (até 12 linhas) |
| 15 | Ferramentas | Python tem uma biblioteca para cada etapa | 8 | pandas, NumPy, SQLAlchemy com PyMySQL, Matplotlib e Faker: o que cada uma faz e onde entra na prática |
| 16 | Ferramentas | O pandas 3.0 mudou duas regras que pegam iniciantes | 4 | Coluna de texto vira `str`; atribuição encadeada deixa de funcionar, use `.loc` |
| 17 | Ferramentas | O Power BI tem três camadas: Power Query, modelo e DAX | 6 | Diagrama das 3 camadas; é o destino do Dia 2 |
|  | Intervalo |  | 10 |  |
| 18 | Engenharia | O dado percorre um ciclo de vida | 6 | Diagrama de 5 etapas: geração, ingestão, armazenamento, transformação, entrega. Voltar a ele nos slides seguintes |
| 19 | Engenharia | Um banco opera, outro analisa: OLTP × OLAP | 6 | Duas colunas com o AgroMaq: tabelas do dia a dia × tabelas feitas para análise |
| 20 | Engenharia | ETL × ELT: a diferença é onde a transformação acontece | 6 | Dois fluxos lado a lado com o T em posições diferentes. O ETL não morreu |

| # | Bloco | Título do slide | Min | Visual e fala-chave |
|---|---|---|---|---|
| 21 | Engenharia | Dado real chega sujo | 6 | Defeitos: nulo, duplicado, valor sentinela, órfão, formato, texto inconsistente. Alerta: nem todo pico é erro |
| 22 | Engenharia | Rodar duas vezes não pode duplicar | 6 | Idempotência (elevador com o botão apertado 5 vezes), staging persistente e transação; base: palestra do Beauchemin |
| 23 | Engenharia | O modelo estrela separa fatos de dimensões | 5 | Cupom fiscal (fato) ligado ao cadastro (dimensão); esboço do DW do AgroMaq |

## Prática do Dia 1 (85 min)

Os alunos chegam com tudo instalado, e os instrutores já geraram o CSV sujo. Em aula só se lê, perfila, trata e carrega.

| Etapa | Min | Os alunos fazem | Demo do instrutor |
|---|---|---|---|
| P1 | 10 | Conectar no MySQL e explorar o banco | Hierarquia unidade, setor, linha, máquina, sensor, com as consultas do `04_consultas_validacao.sql` |
| P2 | 15 | Carregar o CSV sujo no staging (tudo em `VARCHAR`) e perfilar com SQL | Contar nulos, duplicados, mínimos e máximos |
| P3 | 25 | Transformar com SQL, uma regra por defeito; as linhas rejeitadas vão para a quarentena | Rodar a transformação até ver o log |
| P4 | 15 | Repetir o perfilamento em pandas: `read_csv`, `info`, `describe`, `isna`, `duplicated`, `.loc` | Comparar o resultado com o do SQL |
| P5 | 10 | Carregar na tabela tratada e validar contra o gabarito | Rodar a carga duas vezes e comparar a contagem |

| Etapa | Min | Os alunos fazem | Demo do instrutor |
|---|---|---|---|
| P6 | 10 | Checkpoint: o que o gabarito mostra e o pico legítimo que não deveria ser apagado | Discussão com a turma |

### IA na engenharia e fechamento (25 min)

| # | Título do slide | Min | O que acontece |
|---|---|---|---|
| 24 | A IA acelera, quem valida é você | 8 | Demo ao vivo: pedir a uma IA o SQL que acha leituras duplicadas e revisar linha a linha |
| 25 | Delegue a escrita, não a conferência | 4 | Checklist: dar o schema como contexto, testar numa amostra, comparar contagens, não colar dado sensível |
| 26 | Dado ruim derruba a IA também | 3 | Qualidade de dado alimenta modelos e assistentes; o mesmo defeito vira resposta errada |
| 27 | Hoje o dado ficou confiável; amanhã ele vira decisão | 4 | Recap e gancho para o Power BI |
| 28 | O que instalar antes do Dia 2 | 3 | Power BI Desktop e o conector MySQL, com teste de conexão |
| 29 | Perguntas e feedback | 3 | Anotar as dúvidas para a próxima turma |

Se atrasar, a parada de segurança é aos 8 min da P3: entregar a transformação completa e ir direto à carga. Depois, reduzir a P4 a uma demonstração do instrutor.

## Dia 2 — Do modelo dimensional ao dashboard, e a Ciência de Dados

**Fio condutor do dia:** terminamos o pipeline (staging → DW) e então o dado limpo vira decisão: Power BI, DAX, IA dentro do dashboard, e um olhar teórico sobre Ciência de Dados. Total: 230 min de conteúdo + 10 min de intervalo.

| Bloco | Min | Slides | Prática |
|---|---|---|---|
| Recap e meta do dia | 10 | 1–2 | — |
| Fim da Engenharia de Dados (carga fato × dimensão) | 40 | 3–5 | E1–E3 (25 min) |
| Como o Power BI funciona | 25 | 6–9 | B1 (6 min) |
| *Intervalo* | *10* | — | — |
| Dashboards | 55 | 10–12 | D1–D3 (40 min) |
| DAX sucinto | 30 | 13–14 | X1–X2 (18 min) |
| IA dentro de dashboards | 20 | 15–16 | A1–A2 (11 min) |
| Ciência de Dados (teoria) | 25 | 17–21 | — (detalhe na seção própria) |
| Insights e conclusões | 15 | 22 | I1 (10 min) |
| Discussão final | 10 | 23 | — |
| **Total de conteúdo** | **230** | **23** | |

## Bloco 1 — Recap e meta do dia (10 min, slides 1–2)

**Slide 1 · Onde paramos (5 min).** Diagrama do pipeline com as cores de papel: origem em Sapphire (OLTP + CSV sujo), staging, ETL, destino em Emerald (DW). Marcar o que já está pronto no Dia 1 (staging carregada, rejeitos em `etl_rejeito`, limpeza validada contra o gabarito) e o que falta (carga no modelo estrela). Pergunta rápida à turma: "quem lembra qual defeito mais pegou vocês ontem?" — usa a resposta para retomar o vocabulário (nulo, duplicata, sentinela, órfão).

**Slide 2 · Meta do dia (5 min).** Três entregas visíveis até o fim da noite: (1) DW carregado e reconciliado, (2) dashboard de 3 páginas no Power BI, (3) três insights escritos com o número que os sustenta. Mostrar o dashboard final pronto (print) como "destino" antes de construir.

## Bloco 2 — Fim da Engenharia de Dados (40 min, slides 3–5 + prática E1–E3)

**Slide 3 · Fato × dimensão (5 min).** Fato = o que aconteceu e se mede (uma leitura, uma ordem de produção); dimensão = o contexto para fatiar (quando, onde, qual máquina, qual produto). Analogia: fato é o verbo e o número, dimensão é "quem/onde/quando".

Granularidade como decisão número 1: `fato_leitura_sensor` = 1 linha por sensor por hora; `fato_producao` = 1 linha por ordem/lote (granularidade exata a confirmar no DDL do DW).

**Slide 4 · O desenho do DW AgroMaq (5 min).** Estrela com as cinco dimensões (`dim_tempo`, `dim_sensor`, `dim_maquina`, `dim_linha`, `dim_produto`) ao redor das duas fatos. Mostrar que a dimensão desnormaliza a hierarquia do OLTP (sensor → máquina → linha → unidade vira uma linha larga). Chave substituta (surrogate key) versus chave natural: por que o DW cria a sua. `dim_cliente` só aparece no desafio de vendas.

**Slide 5 · Carga idempotente (5 min).** Regra de ouro: rodar duas vezes dá o mesmo resultado. Padrões: `INSERT … ON DUPLICATE KEY UPDATE` nas dimensões; fatos carregados por partição (apaga o intervalo e reinsere, ou insere só o que não existe). Ligar com a ideia de Beauchemin (partições imutáveis, staging persistente) já vista no Dia 1. Mostrar a consulta de reconciliação que vamos usar: contagem staging − rejeitos = contagem na fato.

**Prática (25 min):**

| Etapa | Min | O que o aluno faz | Critério de pronto |
|---|---|---|---|
| E1 | 10 | Roda o script de dimensões (`dim_tempo` gerada por procedure, demais carregadas da staging limpa) | Contagens por dimensão batem com o gabarito |
| E2 | 10 | Roda a carga das fatos a partir da staging, com lookup das chaves substitutas | `fato_leitura_sensor` e `fato_producao` com linhas > 0 e sem chave nula |
| E3 | 5 | Roda tudo **de novo** e confere que nada duplicou; roda a reconciliação com o banco limpo | Mesma contagem antes e depois; diferença vs. banco limpo explicada pelos rejeitos |

Parada de segurança: se até o minuto 6 da E2 mais de 5 alunos estiverem travados, o instrutor projeta a carga e a turma segue com o DW pré-carregado (plano B guardado em dump).

## Bloco 3 — Como o Power BI funciona (25 min, slides 6–9 + B1)

**Slide 6 · As três peças (5 min).** Power BI Desktop (onde se constrói), Service (onde se publica e compartilha) e o ciclo "conectar → transformar → modelar → visualizar". Deixar claro que na aula ficamos no Desktop; o Service é só citado.

**Slide 7 · Power Query (5 min).** O ETL leve do analista: passos aplicados, tipos, filtros, mesclagem. Comparar com o que fizemos no pipeline: "o que cabe aqui e o que deve ficar no DW?" Regra prática: limpeza pesada e regra de negócio no DW; ajuste de apresentação no Power Query.

**Slide 8 · Modelo estrela no Power BI (5 min).** Relacionamentos um-para-muitos, direção do filtro, tabela fato no centro. O DW que acabamos de carregar já vem no formato que o Power BI "quer" — essa é a prova do porquê de modelar. Mostrar o diagrama do modelo na paleta (fato em Emerald, dimensões em Sapphire).

**Slide 9 · Coluna × medida (4 min).** Coluna é calculada linha a linha e ocupa memória; medida é calculada na hora, conforme o filtro. Por que 2,15 milhões de linhas pedem medidas, não colunas. Importar × DirectQuery em uma frase (aula usa Importação sobre o recorte).

**B1 · Conectar ao DW (6 min).** O aluno conecta o Power BI ao MySQL do DW e carrega as 5 dimensões + 2 fatos. Pré-requisito: Oracle MySQL Connector/NET instalado nas máquinas (testar antes — ver Pendências). **Plano B:** exportar as tabelas do DW em CSV e importar por Texto/CSV, sem perder a aula.

*Intervalo — 10 min.*

## Bloco 4 — Dashboards (55 min, slides 10–12 + D1–D3)

**Slide 10 · Pergunta antes do gráfico (5 min).** Todo dashboard responde a uma pergunta de alguém que decide. Exemplo: "a gerente da linha de tratores quer saber se alguma máquina está saindo da faixa de operação". Estrutura: KPIs no topo, tendência no meio, detalhe embaixo.

**Slide 11 · Escolha do visual (5 min).** Tabela de decisão: comparar categorias → barras; evolução no tempo → linhas; composição → barras empilhadas (pizza só com 2–3 fatias); relação entre duas variáveis → dispersão; valor único → cartão. O que evitar: 3D, excesso de cores, eixos truncados.

**Slide 12 · Hierarquia visual e a paleta (5 min).** Usar a paleta como linguagem: Sapphire para o dado normal, Emerald para meta atingida/sucesso, Gold para atenção e desvio. Fundo claro (#EDF2F4) nos slides de conteúdo ou Emerald nas capas e transições (decisão tomada para proteger o projetor). Um destaque por tela.

**Prática (40 min):**

| Página | Min | Conteúdo | Perguntas respondidas |
|---|---|---|---|
| D1 · Visão executiva | 15 | Cartões (produção total, % refugo, leituras no período), barras por linha/unidade, segmentação por mês e unidade | Quanto produzimos e onde perdemos? |
| D2 · Sensores | 15 | Linha temporal de leituras por tipo de sensor, filtro por máquina, destaque das leituras fora da faixa (Gold) | Alguma máquina está saindo do normal? |
| D3 · Produção e refugo | 10 | Matriz máquina × motivo de não conformidade, dispersão volume × refugo | Onde está a causa do refugo? |

Cada etapa termina com um "checkpoint": o instrutor projeta a tela esperada e a dupla compara.

## Bloco 5 — DAX sucinto (30 min, slides 13–14 + X1–X2)

**Slide 13 · Contexto de filtro (6 min).** A ideia mais importante do DAX: a mesma medida dá resultados diferentes conforme a linha, o filtro e a segmentação em que está. Demonstrar com uma medida simples sendo usada em um cartão, em uma matriz e com uma segmentação ligada.

**Slide 14 · As medidas que resolvem 80% (6 min).** `SUM`, `COUNTROWS`, `DIVIDE` (divisão segura), `CALCULATE` (muda o contexto), `FILTER`, e uma de inteligência de tempo (`DATEADD` ou `SAMEPERIODLASTYEAR`, com a tabela de datas marcada). Só o necessário; o resto fica como material de apoio.

**X1 · Cinco medidas (12 min).** Total produzido; % de refugo (`DIVIDE`); nº de leituras fora da faixa (`CALCULATE` + condição); % de leituras fora da faixa; variação vs. mês anterior. Os nomes exatos das colunas serão fechados quando o DDL do DW existir.

**X2 · Depurar com IA (6 min).** O aluno cola uma medida que dá resultado estranho (erro plantado pelo instrutor) em uma IA do navegador, pede explicação e correção, **e valida o resultado contra o número do SQL**. Reforça a regra da aula: IA propõe, o dado confirma.

## Bloco 6 — IA dentro de dashboards (20 min, slides 15–16 + A1–A2)

**Slide 15 · Recursos de IA no Power BI (5 min).** Visuais que já vêm no Desktop: *Key Influencers*, *Decomposition Tree* (divisão por IA), *Smart Narrative*, *Q&A*, detecção de anomalias no gráfico de linhas com eixo de data, *Quick Insights*. Segundo o exemplo oficial

da Microsoft, dá para explorar esses recursos no Desktop sem licença adicional; **Copilot é outra história**: exige capacidade paga (Fabric F2+ ou Premium P1+) e habilitação no tenant, então provavelmente não estará disponível na sala.

**Slide 16 · O padrão vale para qualquer ferramenta (4 min).** Os mesmos quatro padrões aparecem em Tableau, Looker, Metabase, Superset e afins: (1) pergunta em linguagem natural vira consulta, (2) narrativa automática do que mudou, (3) detecção de anomalia, (4) assistente que escreve fórmula/SQL. Slide conceitual — nomes de recursos específicos de outras ferramentas ficam para confirmar antes da aula. Fechar com os riscos: alucinação, métrica errada com cara de certa, vazamento de dado sensível ao colar no chat.

**A1 · Rodar os recursos sobre o AgroMaq (8 min).** Em dupla: *Key Influencers* sobre "leitura fora da faixa" (o que mais influencia?), *Decomposition Tree* sobre refugo (por máquina → motivo → turno) e anomalia na linha de temperatura. Testar tudo no dataset antes da aula; se algum recurso não render, trocar por outro e avisar na pendência.

**A2 · Conferir o que a IA disse (3 min).** Cada dupla escolhe uma afirmação da IA e a confirma com uma consulta SQL ou uma medida DAX. Discussão curta: quando bateu, quando não bateu.

## Bloco 7 — Ciência de Dados (25 min, slides 17–21)

Teoria com exemplos aplicados ao AgroMaq, sem rodar modelo. Roteiro detalhado na seção **Bloco de Ciência de Dados**. Posição no dia: depois do dashboard, porque o aluno acabou de ver o que o dado "diz" e agora vê o que ele "prevê".

## Bloco 8 — Insights e conclusões (15 min, slide 22 + I1)

**Slide 22 · Do número à decisão (5 min).** Estrutura de um insight: *o que vimos → por que importa → o que fazer*. Exemplo ruim ("o refugo é 4%") versus bom ("o refugo da Linha X sobe no turno da noite; sugerimos revisar a calibração da máquina Y").

**I1 · Três insights (10 min).** Cada dupla escreve três insights do dashboard, cada um com o número que o sustenta e uma ação sugerida. Duas duplas apresentam em 1 min cada.

## Bloco 9 — Discussão final (10 min, slide 23)

**Slide 23 · Mapa da carreira e próximos passos (4 min).** Recapitular o trajeto: dado bruto → pipeline → DW → dashboard → insight, e para onde cada trilha (analista, engenheiro, cientista) continua. Indicar certificações iniciais (PL-300 para análise, DP-600 e DP-700 para quem vai para engenharia no ecossistema Microsoft) e materiais para continuar.

**Debate (6 min).** Perguntas abertas: "qual parte do pipeline você acha que mais quebra no mundo real?", "o que você deixaria a IA fazer sozinha e o que não?". Coletar feedback e, se couber, uma pergunta de cada aluno sobre carreira.

## Bloco de Ciência de Dados (Dia 2, 25 min, slides 17–21)

**Formato:** teoria pura, sem rodar modelo. Cada slide ancora o conceito em um exemplo do AgroMaq (sensores, produção, BOM, clientes). Objetivo: o aluno sai sabendo o que um cientista faz, como trabalha, com que conceitos e ferramentas, como o cargo difere dos vizinhos e quais portas o mercado abre.

| Slide | Min | Tema |
|---|---|---|
| 17 | 5 | O que o cientista de dados faz e como trabalha |
| 18 | 5 | Conceitos e matemática aplicada |
| 19 | 5 | Cinco problemas do AgroMaq que viram ciência de dados |
| 20 | 5 | Cargos vizinhos e tecnologias |
| 21 | 5 | Mercado, certificações e IA na ciência de dados |

**Slide 17 · O trabalho e o método (5 min).** Ciclo de trabalho: pergunta de negócio → dados (o que o engenheiro entregou) → exploração → modelagem → validação → entrega (relatório, API, aplicação) → monitoramento. Destacar que a maior parte do tempo vai para entender o problema e preparar dado, e que o cientista **depende** da engenharia: sem o pipeline de ontem, não há modelo hoje. Diferença de pergunta: o analista pergunta "o que aconteceu?", o cientista pergunta "o que vai acontecer?" e "o que fazer?". Conectar com os níveis de análise dos livros do projeto (descritiva, diagnóstica, preditiva, prescritiva).

**Slide 18 · Conceitos e matemática aplicada (5 min).** Sem fórmulas pesadas; a ideia de cada ferramenta e onde aparece:

| Área | Para que serve | Onde aparece no AgroMaq |
|---|---|---|
| Estatística descritiva | Resumir: média, mediana, desvio, percentis | Faixa normal de temperatura de um sensor |
| Probabilidade e inferência | Medir incerteza; distinguir ruído de sinal | Uma leitura alta é pico legítimo ou falha? |
| Álgebra linear | Dados como vetores e matrizes | Cada máquina descrita por um vetor de sensores |

| Área | Para que serve | Onde aparece no AgroMaq |
|---|---|---|
| Cálculo e otimização | Treinar modelos minimizando erro | "Descer a ladeira" do erro de previsão |

Conceitos de modelagem: aprendizado supervisionado (tem resposta conhecida) × não supervisionado (descobre grupos); treino/teste; *overfitting* (decorar em vez de aprender); métricas por tipo de problema. Lembrar do "pico legítimo" que plantamos no dado sujo: quem não conhece o negócio marca como erro.

**Slide 19 · Cinco problemas do AgroMaq (5 min).** Cada um com tipo de problema, dado de entrada e pergunta de negócio:

| Problema | Tipo | Dado | Pergunta |
|---|---|---|---|
| Prever falha de máquina | Classificação (supervisionado) | Leituras de sensor + histórico de paradas | Qual máquina deve parar nos próximos dias? |
| Detectar comportamento anormal | Anomalia (não supervisionado) | Leituras de sensor por hora | O que foge do padrão da própria máquina? |
| Prever demanda | Séries temporais / regressão | Vendas e produção por mês | Quantos tratores produzir no próximo trimestre? |
| Segmentar clientes | Agrupamento (clustering) | Clientes por país, mercado, volume | Existem perfis de cliente distintos? |
| Achar causas de refugo | Explicação / importância de variáveis | Produção + motivos de não conformidade | Que fatores mais pesam no refugo? |

Fechamentos possíveis (se sobrar tempo): estoque e BOM (prever consumo de matéria-prima a partir da estrutura de produto) como problema de otimização. Ligar com os visuais de IA vistos no dashboard: *Key Influencers* é o primo simples do problema 5.

**Slide 20 · Cargos vizinhos e tecnologias (5 min).** Quadro comparativo:

| Cargo | Foco | Entrega típica | Ferramentas comuns |
|---|---|---|---|
| Analista de dados | Responder perguntas, dashboards | Relatório, painel | SQL, Power BI, Excel |

| Cargo | Foco | Entrega típica | Ferramentas comuns |
|---|---|---|---|
| Engenheiro de dados | Pipelines, qualidade, DW | Tabelas confiáveis | SQL, Python, orquestração, nuvem |
| Engenheiro de analytics | Modelagem e transformação para análise | Modelos de dados testados | SQL, dbt |
| Cientista de dados | Modelos e experimentos | Previsão, análise avançada | Python, pandas, scikit-learn, estatística |
| Engenheiro de ML | Colocar modelo em produção | Serviço de modelo monitorado | Python, MLOps, nuvem |
| Engenheiro de IA | Construir aplicações com modelos de linguagem | Assistentes, agentes | APIs de LLM, RAG, Python |

Bibliotecas de ciência de dados a citar como "o que se vê na prática": pandas, NumPy, scikit-learn (as duas primeiras o aluno já usou), e deep learning (PyTorch, TensorFlow) só como menção. Nota do mercado: a fronteira entre cientista e engenheiro de IA está se movendo (KDnuggets, jan/2026).

**Slide 21 · Mercado, certificações e IA na ciência (5 min).**

- **Mercado no Brasil:** mais de 100 mil vagas de dados, segundo o guia da Alura com base no State of Data; faixas salariais citadas (Glassdoor): júnior R$ 3 mil a 5 mil, pleno R$ 5 mil a 9 mil; 40–50% das vagas remotas ou híbridas. Apresentar como ordem de grandeza e com a fonte no slide.
- **Referência internacional:** mediana de cientista de dados perto de US$ 170 mil (Levels.fyi) e engenheiro de IA acima de US$ 200 mil (Built In), segundo o KDnuggets — dados dos EUA, não transpor para o Brasil.
- **Certificações:** para o iniciante, PL-300 (análise), DP-600 (análise/engenharia no Fabric), DP-700 (engenharia no Fabric; atualização da versão em inglês em 19/out/2026), Databricks Data Engineer Associate, AWS Data Engineer Associate (DEA-C01) e Google Professional Data Engineer. Para ciência/ML especificamente, citar as trilhas das três nuvens, **confirmando nomes e status vigentes antes da aula**.
- **IA na ciência de dados:** assistentes que escrevem código de exploração, sugerem features e explicam resultados; o risco é aceitar um modelo "que funciona" sem entender a métrica ou o vazamento de dados. Mensagem final do bloco: a base (estatística, pensamento crítico, dado bem preparado) vale mais que a ferramenta da moda.

# IA em cada área

**Princípio único da aula:** a IA propõe, o dado confirma. Os alunos têm IA gratuita no navegador (ou a própria conta, se trouxerem notebook), então a IA entra em três momentos práticos e em um slide por área. Em todos, a etapa final é validar contra o banco, o gabarito ou uma consulta SQL.

| Área | Onde a IA ajuda | Onde está na aula | Validação obrigatória |
|---|---|---|---|
| **Análise** | Perguntar em linguagem natural, narrar tendências, achar anomalias, escrever DAX | Dia 2, blocos 5 e 6 (X2, A1, A2) | Conferir o número com SQL ou medida |
| **Engenharia** | Escrever e explicar SQL/ETL, sugerir testes de qualidade, ler mensagem de erro | Dia 1, bloco "IA na engenharia" (slides 24–29) | Rodar em amostra e reconciliar com o gabarito |
| **Ciência** | Esboçar exploração, sugerir features, explicar métricas | Dia 2, slide 21 (teoria) | Entender a métrica e checar vazamento de dados |
| **Dashboards** | Visuais de IA, narrativa automática, Q&A | Dia 2, slides 15–16 e A1 | Comparar com o dado de origem |

## Análise e dashboards

- **Recursos nativos do Power BI Desktop:** *Key Influencers*, *Decomposition Tree*, *Smart Narrative*, *Q&A*, detecção de anomalias e *Quick Insights* (conforme o exemplo oficial da Microsoft). A página não declara requisitos de licença para os visuais; o exemplo diz que dá para explorar no Desktop. **Testar no AgroMaq antes da aula**, porque alguns visuais exigem volume e tipo de dado específicos para render algo útil.
- **Copilot no Power BI:** exige capacidade paga (Fabric F2 ou superior, ou Premium P1 ou superior) e habilitação pelo administrador do tenant; não funciona em SKUs de teste. Na sala, tratar como indisponível e usar uma demonstração gravada ou slides se alguém do time tiver acesso.
- **Qualquer ferramenta:** o mesmo conceito vale em outras plataformas de BI; ensinar o padrão, não o botão.

### Engenharia de dados

- Pedir ao assistente o SQL de uma carga, a explicação de um erro do MySQL, ou testes de qualidade (checagem de nulos, duplicatas, órfãos).
- **Experimento didático do Dia 1:** o aluno pede para a IA "limpar" uma tabela suja e compara o resultado com o gabarito — evidencia onde a IA acerta (formato, padronização) e onde erra (regra de negócio, sentinela, pico legítimo).
- Tendência a citar sem aprofundar: ferramentas do ecossistema de engenharia estão incorporando agentes (por exemplo, a fusão Fivetran + dbt Labs, concluída em 1º/jun/2026, anuncia recursos voltados a agentes), mas o conteúdo exato dos produtos deve ser conferido antes de citar.

### Ciência de dados

- Assistentes ajudam a explorar e esboçar código, mas o cientista continua dono da pergunta, da métrica e da interpretação. Exemplo para o slide: pedir "preveja falha" e receber um modelo com 99% de acurácia porque quase nunca há falha — discutir por que a métrica engana.

### Riscos a ensinar nas três áreas

1. **Alucinação com cara de certeza:** resposta fluente e errada.
2. **Métrica errada:** a IA calcula o que você pediu, não o que você quis dizer.
3. **Dado sensível no chat:** não colar dados reais de cliente em ferramentas públicas (no curso o dado é fictício, mas a regra se ensina).
4. **Dependência:** quem não entende o SQL que a IA escreveu não consegue depurar quando quebra.

## Bibliotecas e ferramentas

Cada uma aparece **na teoria** (um slide curto: o que é, para que serve) e **na prática** (o aluno usa ao vivo), exceto onde indicado.

| Ferramenta | Teoria (onde) | Prática (onde) | Observação |
|---|---|---|---|
| **MySQL 8** | Dia 1, ferramentas (13–17) | Dia 1 P1–P3, P5; Dia 2 E1–E3 | Banco `agromaq_industrial` limpo + staging + DW |

| Ferramenta | Teoria (onde) | Prática (onde) | Observação |
|---|---|---|---|
| **pandas** | Dia 1, ferramentas | Dia 1 P4 (perfilamento do CSV sujo: `read_csv`, `info`, `describe`, `isna`, `duplicated`, `.loc`) | Versão 3.0: tipo `str` padrão, Copy-on-Write; usar `.loc` e evitar atribuição encadeada |
| **NumPy** | Dia 1, ferramentas | Dia 1 P4 (opcional: cálculos de faixa e estatística) | Base numérica do pandas; aparece de forma indireta |
| **SQLAlchemy + PyMySQL** | Dia 1, ferramentas | Dia 1 P4 (opcional: ler a staging com `read_sql` para comparar com o SQL) | Ponte Python ↔ MySQL; **confirmar se entra na prática ou fica só na demo do instrutor** |
| **Matplotlib** | Dia 1, ferramentas | Dia 1 P4 (opcional: histograma/boxplot de verificação) | Gráfico rápido; o dashboard é no Power BI |
| **Faker** | Dia 1, ferramentas (dos instrutores) | **Só instrutores** (geração do dado) | Aluno recebe o CSV pronto |
| **scikit-learn** | Dia 2, slide 20 | Não há prática | Apenas conceitual, exemplos no AgroMaq |
| **Power BI Desktop** | Dia 2, bloco 3 | Dia 2 B1, D1–D3, X1–X2, A1 | Windows; conector MySQL precisa de instalação |
| **DAX** | Dia 2, bloco 5 | Dia 2 X1–X2 | Só as medidas essenciais |
| **IA no navegador** | Dia 1 (24–29) e Dia 2 (15–16) | Dia 1 e Dia 2 (X2, A2) | Gratuita, conta do aluno se trouxer notebook |

**Fora do roteiro, só como menção de mercado (um slide):** orquestração (Airflow), transformação em SQL (dbt), processamento distribuído (Spark/Databricks), nuvem (AWS, Azure/Fabric, Google Cloud). Entram como "o que você encontra quando o volume cresce", sem demonstração.

**Ambiente:** máquinas Windows da instituição. Precisam de MySQL client (Workbench ou equivalente), Python com as bibliotecas acima e Power BI Desktop, tudo testado antes. O banco online gratuito (Aiven) hospeda só o OLTP; staging e DW pesados ficam locais ou em dump.

# Pendências, riscos e decisões em aberto

## Decisões para vocês dois

| # | Decisão | Opções | Minha sugestão |
|---|---|---|---|
| 1 | Fundo dos slides | Decidido: tema claro | Fundo #EDF2F4 nos slides de conteúdo; Emerald na capa e transições; Ink Black só no código. Ainda vale testar no projetor do local |
| 2 | SQLAlchemy/Matplotlib na prática | Alunos usam × só demo | Demo do instrutor; P4 já é curta |
| 3 | Granularidade de `fato_producao` | Por ordem × por lote × por dia | Definir ao escrever o DDL do DW |
| 4 | Recorte dos alunos | Janela de datas × amostra de máquinas | Por máquinas: preserva a série temporal inteira de cada uma |
| 5 | Onde roda o DW | Aiven (1 GB) × local × dump | Aiven só para o OLTP; staging e DW locais ou em dump |

## Riscos e o que fazer

| Risco | Impacto | Plano |
|---|---|---|
| Conector MySQL do Power BI (Oracle MySQL Connector/NET) não instalado nas máquinas | B1 trava | Testar numa máquina da instituição antes; plano B: importar CSV exportado do DW |
| Copilot indisponível (exige capacidade paga) | Slide 15 sem demo ao vivo | Usar visuais nativos de IA, testados no AgroMaq; Copilot só por captura de tela |
| Visual de IA não rende com o dado do AgroMaq | A1 fraca | Ensaiar antes e ajustar a pergunta |

| Risco | Impacto | Plano |
|---|---|---|
| Limite de 1 GB do Aiven e desligamento por inatividade | Banco fora do ar na aula | Manter só o OLTP lá; dump local de segurança; ligar o serviço no dia anterior |
| Aiven exige SSL | Falha de conexão em cliente mal configurado | Testar cliente MySQL e Python com SSL |
| Atraso na prática do Dia 1 | P4/P5 espremidas | Parada de segurança aos 8 min da P3 e P4 vira demo |
| Máquinas lentas com 2,15 mi de linhas | Prática demora | Alunos trabalham só com o recorte; volume total pré-carregado |
| Atualização do exame DP-700 (versão em inglês, 19/out/2026) | Slide de certificações desatualizado | Conferir a página oficial na semana da aula |

## O que ainda não existe (trabalho a fazer antes da aula)

1. **Script Python de geração** das leituras (01/01/2026 a 10/10/2026, 1 por hora, sementes fixas) e dos dados de produção.
2. **Script de quebra** (defeitos controlados) que gera o CSV sujo e o **gabarito**.
3. **DDL da staging,** `etl_rejeito` **e** `etl_log`, e do **DW** (5 dimensões + 2 fatos; `dim_cliente` para o desafio).
4. **SQLs de transformação e carga**, e consultas de validação/reconciliação.
5. **Modelo do Power BI** e medidas DAX, já testados com os visuais de IA.
6. **Guia do instrutor** com respostas de cada prática e pontos de parada.
7. **Desafio de vendas** (enunciado e gabarito).
8. Repositório de scripts numerados para os dois trabalharem no mesmo banco sem custo.
9. Registrar no log de mudanças a correção de cidade/estado dos clientes (script já entregue; **não foi executado por mim no seu banco**).

## Próximo passo sugerido

Aprovar este roteiro (ou ajustar), e então seguir para o **design dos slides** na paleta definida. Os scripts de dados podem andar em paralelo, e são eles que destravam as práticas.

# Fontes

## Páginas que abri e li

- The Future of the Data Engineer — Monte Carlo
- Functional Data Engineering: a set of best practices — AI Council
- Enable Copilot for Power BI — Microsoft Learn (requisito de capacidade F2+/P1+)
- MySQL database connector — Microsoft Learn (necessidade do Oracle MySQL Connector/NET)
- Microsoft Certified: Power BI Data Analyst Associate (PL-300)
- Microsoft Certified: Fabric Data Engineer Associate (DP-700) (data da atualização: 19/out/2026)
- pandas 3.0 — blog oficial
- Guia de Analista de Dados — Alura (vagas, faixas salariais; dados atribuídos ao State of Data e ao Glassdoor)
- Fivetran and dbt Labs complete merger — Fivetran
- Data Scientist vs AI Engineer — KDnuggets (valores salariais dos EUA)
- Artificial intelligence sample for Power BI — Microsoft Learn

## Vi apenas em resultados de busca (conferir antes de usar em slide)

- Aiven — MySQL free tier (1 GB, sem cartão, pode ser desligado por inatividade, SSL)
- Copilot capacity in Fabric — Microsoft Learn
- Pages de DP-600, Databricks Data Engineer Associate, AWS DEA-C01 e Google Professional Data Engineer: nomes e escopo vindos de busca, sem abrir a página oficial de cada uma.

## Não consegui ler

- *The Rise of the Data Engineer* (andrewrgoss.com): a página deu erro de redirecionamentos nas duas tentativas. Se quiserem que entre no material, mandem o texto ou o PDF.

## Material do projeto usado

Formulário do curso (docx), PDF "Materiais de Estudo e Roteiro de Slides", `01_modelagem_conceitual.md`, `02_schema.sql`, `03_populacao_base.sql`, `04_consultas_validacao.sql`. Os 11 PDFs de BI e analytics do projeto **ainda não foram abertos**; são candidatos a referência para os slides de Dados e BI e de Dashboards.